



# 神经网络



主讲人 夏至



- 第一部分：作业1 感知机
- 第二部分：作业2 神经网络
- 第三部分：作业3 参数计算
- 第四部分：手写数字分类器编程练习


- 第一部分：作业1 感知机
- 第二部分：作业2 神经网络
- 第三部分：作业3 参数计算
- 第四部分：手写数字分类器编程练习

现有如下训练数据集，正样本点 $M_1(3,3)$ 和 $M_2(4,3)$ ，负样本点 $M_3(1,1)$ ，请利用感知机算法求感知机模型 $f(x) = \text{sign}(w \cdot x + b)$ 。下方表格中已给出了前4步迭代的步骤，第5步迭代中选择 $M_2$ 为误分类点，请补全后续详细的迭代过程。

迭代次数	误分类点	$w$	$b$	超平面
0		(0, 0)	0	0
1	$M_1$	(3, 3)	1	$3x_1 + 3x_2 + 1$
2	$M_3$	(2, 2)	0	$2 + 2x_2$
3	$M_3$	(1, 1)	-1	$x_1 + x_2 - 1$
4	$M_3$	(0, 0)	-2	-2
5	$M_2$			
...				
N	无			

# 感知机


1. 取初值  $w_0 = \mathbf{0}, b_0 = 0$
2.  $M_1$  对应的感知机模型输出为0, 未被正确分类, 更新:  
$$w_1 = w_0 + y_1 x_{M_1} = (3, 3) \quad b_1 = b_0 + y_1 = 1$$
3.  $M_1$  和  $M_2$  已经满足,  $M_3$  对应感知机输出为1, 未被正确分类, 更新:  
$$w_2 = w_1 + y_3 x_{M_3} = (2, 2) \quad b_2 = b_1 + y_3 = 0$$
4. 重复更新步骤, 直至没有误分类点。



参数更新:

$$\begin{aligned} w_{n+1} &= w_n + y_i x_i \\ b_{n+1} &= b_n + y_i \end{aligned}$$

# 感知机



迭代次数	误分类点	w	b	超平面
0		(0, 0)	0	0
1	M1	(3, 3)	1	$3x_1+3x_2+1$
2	M3	(2, 2)	0	$2x_1+2x_2$
3	M3	(1, 1)	-1	$x_1+x_2-1$
4	M3	(0, 0)	-2	-2
5	M2	(4, 3)	-1	$4x_1+3x_2-1$
6	M3	(3, 2)	-2	$3x_1+2x_2-2$
7	M3	(2, 1)	-3	$2x_1+x_2-3$
8	M3	(1, 0)	-4	$x_1-4$
9	M2	(5, 3)	-3	$5x_1+3x_2-3$
10	M3	(4, 2)	-4	$4x_1+2x_2-4$
11	M3	(3, 1)	-5	$3x_1+x_2-5$
12	无	(3, 1)	-5	$3x_1+x_2-5$

感知机模型： $f(\mathbf{x})=\text{sign}(\mathbf{w}\bullet\mathbf{x}+b)$

- 第一部分：作业1 感知机
- 第二部分：作业2 神经网络
- 第三部分：作业3 参数计算
- 第四部分：手写数字分类器编程练习

为什么多层神经网络可以拟合任意函数？其与浅层宽网络的区别是什么？

- 从感知机的角度看
- 从决策边界的角度看



## ●感知机

感知机由两层神经元组成，激活函数设为阶跃函数，如右图所示。

考虑简单的逻辑运算：

对于“与”运算 ( $x_1 \wedge x_2$ )：


可令  $w_1 = w_2 = 1$ ,  $b = -1.5$ , 则  $y = f(x_1 + x_2 - 1.5)$

对于“或”运算 ( $x_1 \vee x_2$ )：

可令  $w_1 = w_2 = 1$ ,  $b = -0.5$ , 则  $y = f(x_1 + x_2 - 0.5)$

对于“非”运算 ( $\neg x_1$ )：





可令  $w_1 = -1$ ,  $w_2 = 0$ ,  $b = 0.5$ , 则  $y = f(-x_1 + 0.5)$



## ●感知机

对于“异或”运算 ( $x_1 \oplus x_2$ ) ?

事实上，如果感知机只有一层神经元，学习能力非常有限。上述的与、或、非问题都是线性可分问题，可以证明存在一个线性超平面将其分开。但对于异或这样简单的非线性问题，单层感知机不能解决。





## ●感知机

那么，多层感知机可以实现异或问题吗？

考虑在之前单层感知机的基础上增加一层隐含层，网络结构如下图所示：

只要我们设置好合适的权重和阈值，则异或问题迎刃而解。



## ●感知机

由此可见，单层神经网络可以解决线性问题，多层神经网络则将单层神经网络联立起来，解决了非线性问题。

万能近似定理表明，两层神经网络已经可以拟合任意函数。

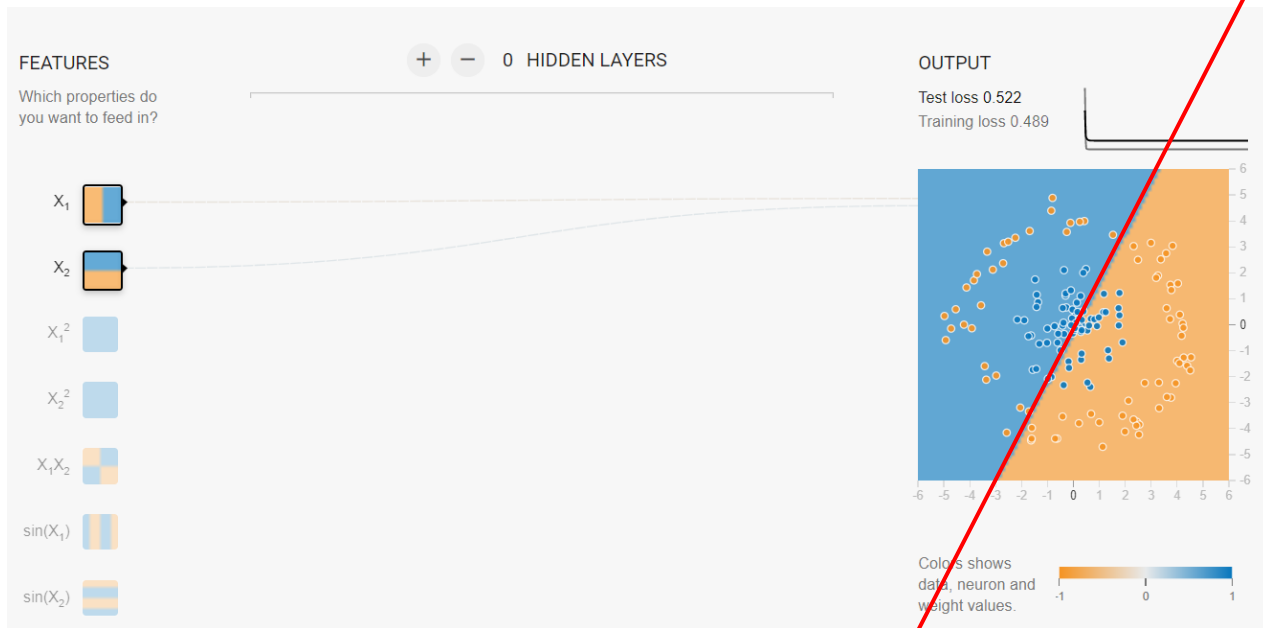
## ●决策边界

单层神经网络只能划分出一条超平面，可以解决线性可分问题；

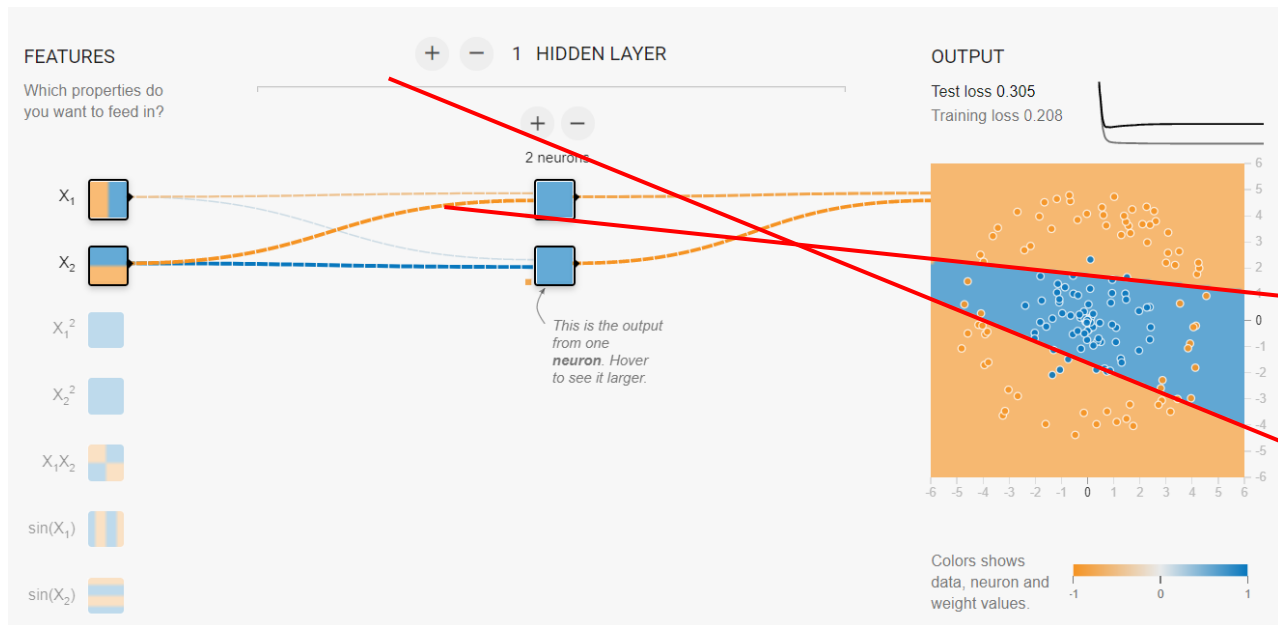
多层神经网络可以划分出多条超平面，可以解决线性不可分问题；

# 神经网络

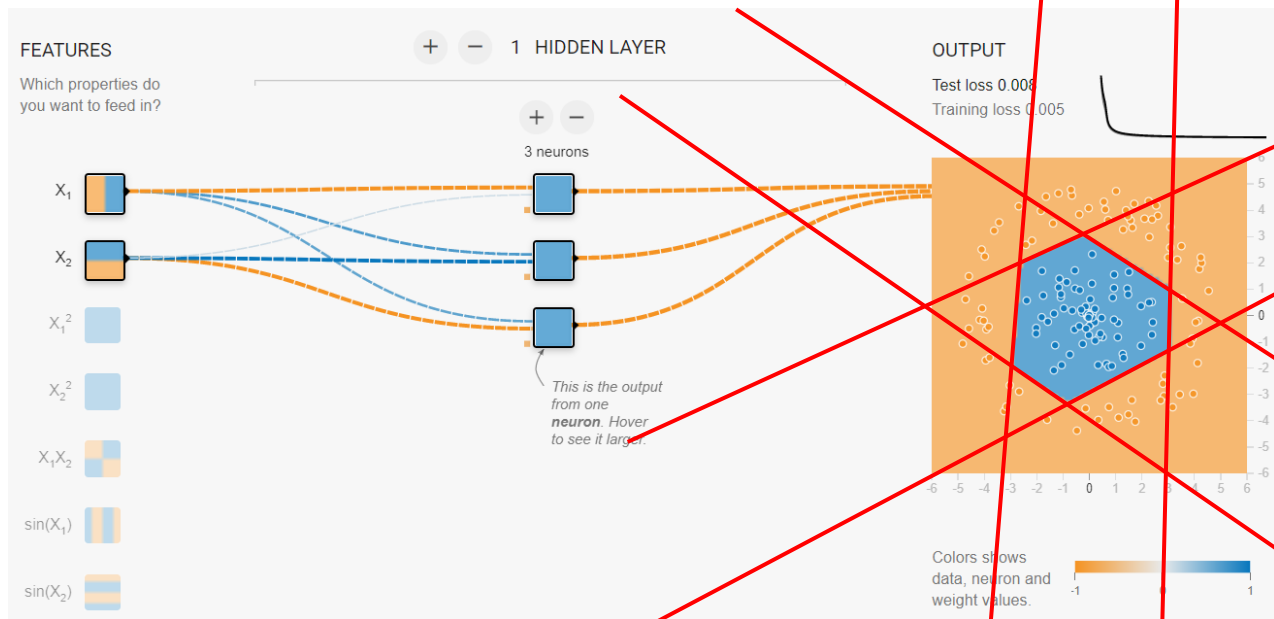
## ● 决策边界



## ● 决策边界



## ● 决策边界





- 第一部分：作业1 感知机
- 第二部分：作业2 神经网络
- 第三部分：作业3 参数计算
- 第四部分：手写数字分类器编程练习

# 参数计算

- 手写数字识别案例中，如果输入的图片尺寸是 $28*28$ 大小，则输入层维度为：

$$28*28=784$$

- 整个网络结构为：[784 30 10]

- 则参数量为：


- 输入层到隐藏层权重： $784*30=23520$

- 输入层到隐藏层偏置：30

- 隐藏层到输出层权重： $30*10=300$

- 隐藏层到输出层偏置：10

因此，参数量共为： $(784+1)*30+(30+1)*10=23860$



- 假设图片变成了 $256*256$ ，则输入层维度为： $256*256=65536$

- 整个网络结构为：[65536 30 10]


- 计算方法与之前一样，参数量共为： $(65536+1)*30+(30+1)*10=1966420$

## ●降低计算复杂度

- 采用更合适的梯度下降方法
- 减小输入数据维度

## ●提升计算速度


- 并行加速
- GPU加速
- 指令集加速



- 第一部分：作业1 感知机
- 第二部分：作业2 神经网络
- 第三部分：作业3 参数计算
- 第四部分：手写数字分类器编程练习

# 手写数字分类器编程练习

```
● def sigmoid(z):  
    return 1/(1 + np.exp(-z))  
  
● def sigmoid_prime(z):  
    return sigmoid(z)*(1-sigmoid(z))
```



$$f(x) = \frac{1}{1 + e^{-x}}$$

$$f'(x) = -\frac{1}{(1 + e^{-x})^2} * e^{-x} * (-1)$$

$$= \frac{e^{-x}}{(1 + e^{-x})^2}$$

$$= \frac{1}{1 + e^{-x}} * \frac{e^{-x}}{1 + e^{-x}}$$

$$= f(x) * (1 - f(x))$$

# 手写数字分类器编程练习

## ●train

对于每轮训练：

打乱训练集数据，将训练集划分成若干个batch；

每次用batch更新神经网络参数：

计算出每个batch平均的权重和偏置更新情况

再乘上一个预设的学习率来控制梯度下降收敛情况

然后更新权重和偏置

## ●evaluate

前向计算神经网络输出，获取输出向量的最大索引，即为预测值。统计所有测试集数据的预测值与真实值差异返回准确率

# 手写数字分类器编程练习


- `[0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15]` `training_data`
- `[2, 5, 7, 9, 13, 12, 0, 8, 10, 3, 1, 15, 4, 14, 6, 11]` `random.shuffle`
- `[2, 5, 7, 9], [13, 12, 0, 8], [10, 3, 1, 15], [4, 14, 6, 11]` `mini_batches`
- 假设先对第一个mini\_batch`[2, 5, 7, 9]`进行update
  - 初始设置`nabla_b`, `nabla_w`, 然后遍历mini\_batch的所有数据
    - `training_data[2][0]: 784*1` `training_data[2][1]: 10*1`
    - backprop计算`delta_nabla_b`, `delta_nabla_w`, 然后更新`nabla_b`, `nabla_w`
    - 在这个过程中`weights`和`biases`保持不变
  - 完成所有mini\_batch的遍历, 我们可以获得最后的`nabla_b`, `nabla_w`, 然后除以`len(mini_batch)`以获得mini\_batch内数据的平均`nabla_b`, `nabla_w`, 为了更好的收敛, 我们需要通过设置学习率`eta`来控制梯度下降步长, 因此, 对每个参数进行更新:

$$w_{ij}^l = w_{ij}^l - eta * \frac{\nabla w_{ij}^l}{len(mini\_batch)}$$

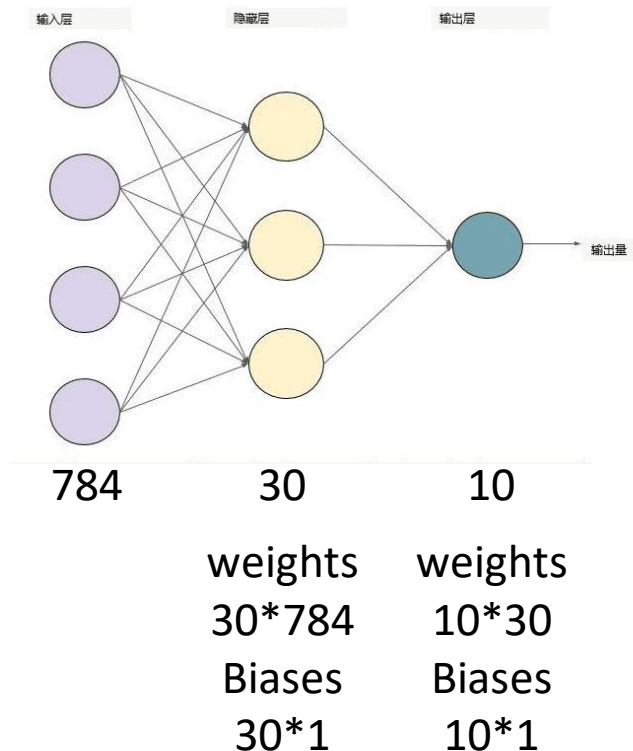
$$b_i^l = b_i^l - eta * \frac{\nabla b_i^l}{len(mini\_batch)}$$

# 手写数字分类器编程练习

## ● Backprop——前向计算



## ● 存储神经网络每层输出a和z，用于计算delta





# 手写数字分类器编程练习

## ● Backprop——反向传播

$$\delta_i^{(L)} = - \left( y_i - a_i^{(L)} \right) f' \left( z_i^{(L)} \right) \quad \text{输出层}$$

$$\delta_i^{(l)} = \left( \sum_{j=1}^{n_{l+1}} \delta_j^{(l+1)} \Theta_{ji}^{(l+1)} \right) f' \left( z_i^{(l)} \right) \quad \text{隐藏层}$$

$$\frac{\partial E}{\partial \Theta_{ij}^{(l)}} = \delta_i^{(l)} a_j^{(l-1)}$$

$$\frac{\partial E}{\partial b_i^{(l)}} = \delta_i^{(l)}$$

$$\Theta^{(l)} = \Theta^{(l)} - \mu \frac{\partial E_{total}}{\partial \Theta^{(l)}}$$

$$= \Theta^{(l)} - \frac{\mu}{N} \sum_{i=1}^N \frac{\partial E_{(i)}}{\partial \Theta^{(l)}}$$

$$\mathbf{b}^{(l)} = \mathbf{b}^{(l)} - \mu \frac{\partial E_{total}}{\partial \mathbf{b}^{(l)}}$$

$$= \mathbf{b}^{(l)} - \frac{\mu}{N} \sum_{i=1}^N \frac{\partial E_{(i)}}{\partial \mathbf{b}^{(l)}}$$



感谢各位聆听 !  
Thanks for Listening

