

深度学习理论与实践

第6课：目标检测

主讲人 洪振

中国科学院自动化研究所博士
模式识别国家重点实验室



□ 目标：

- 了解目标识别的原理
- 对比目标识别的传统方法和深度学习优劣
- 利用Pytorch构建目标识别网络

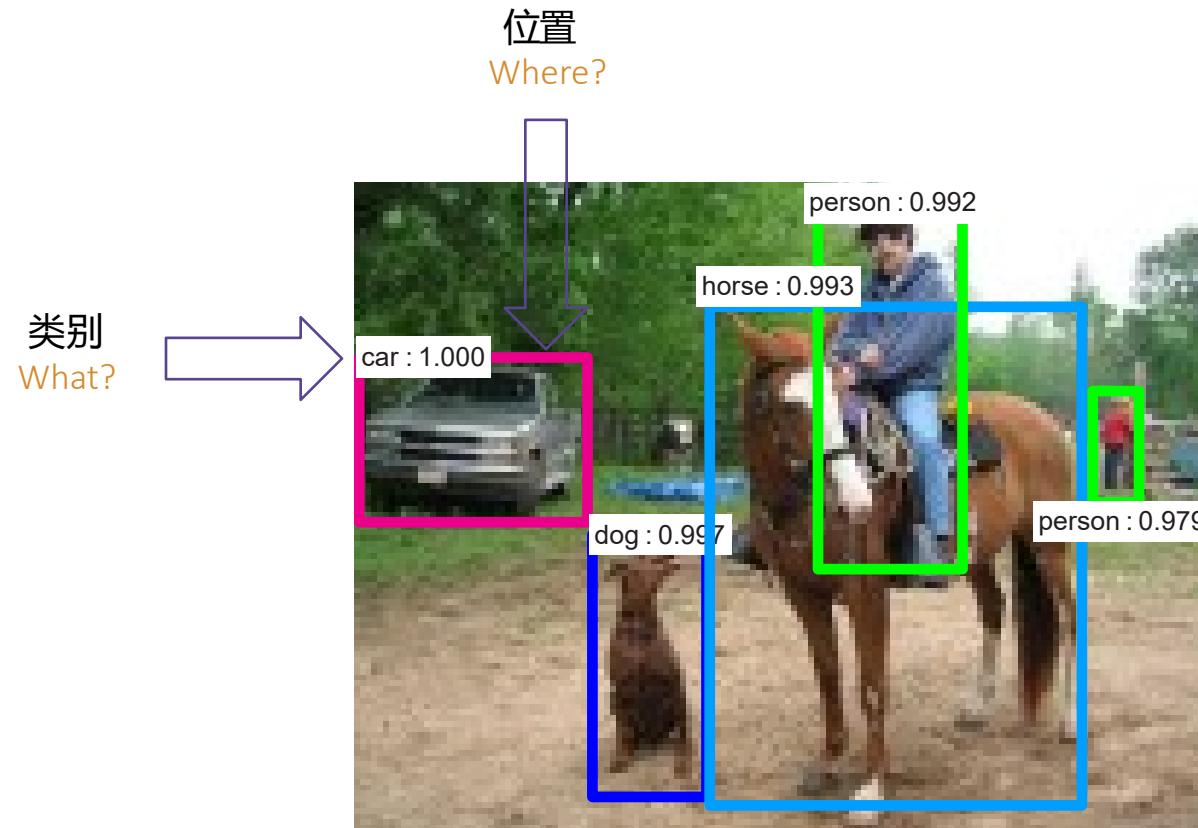
□ 基础储备：

- 熟悉Pytorch
- 掌握CNN的基本流程

- ✓ 目标识别介绍
- ✓ 传统方法和深度学习对比
- ✓ Faster RCNN介绍
- ✓ Faster RCNN代码详解

目标识别—object recognition

定义

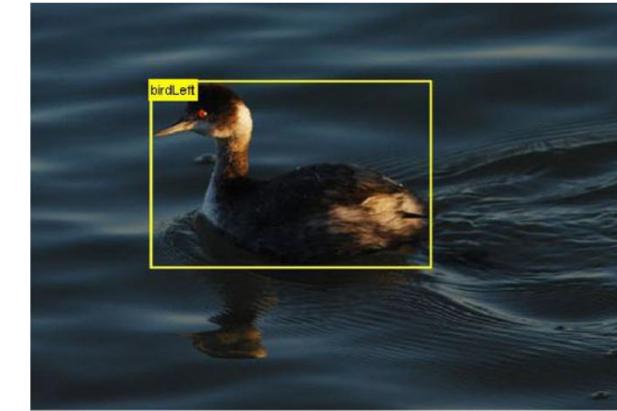
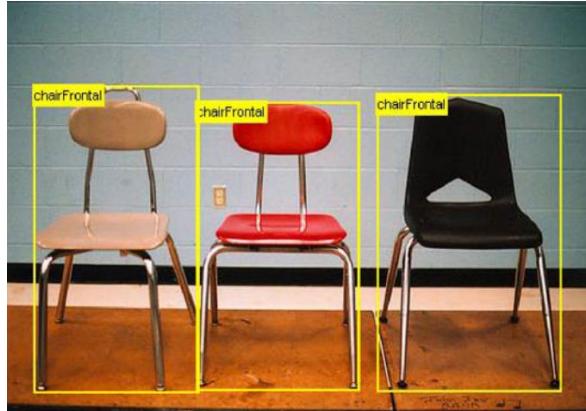


常用数据集：

VOC2007 VOC2012: 20类, 简单场景, 11,530张图像, 27,450物体
COCO: 91类, 复杂场景, 328,000图像, 2,500,000物体

目标识别—object recognition

Pascal Examples



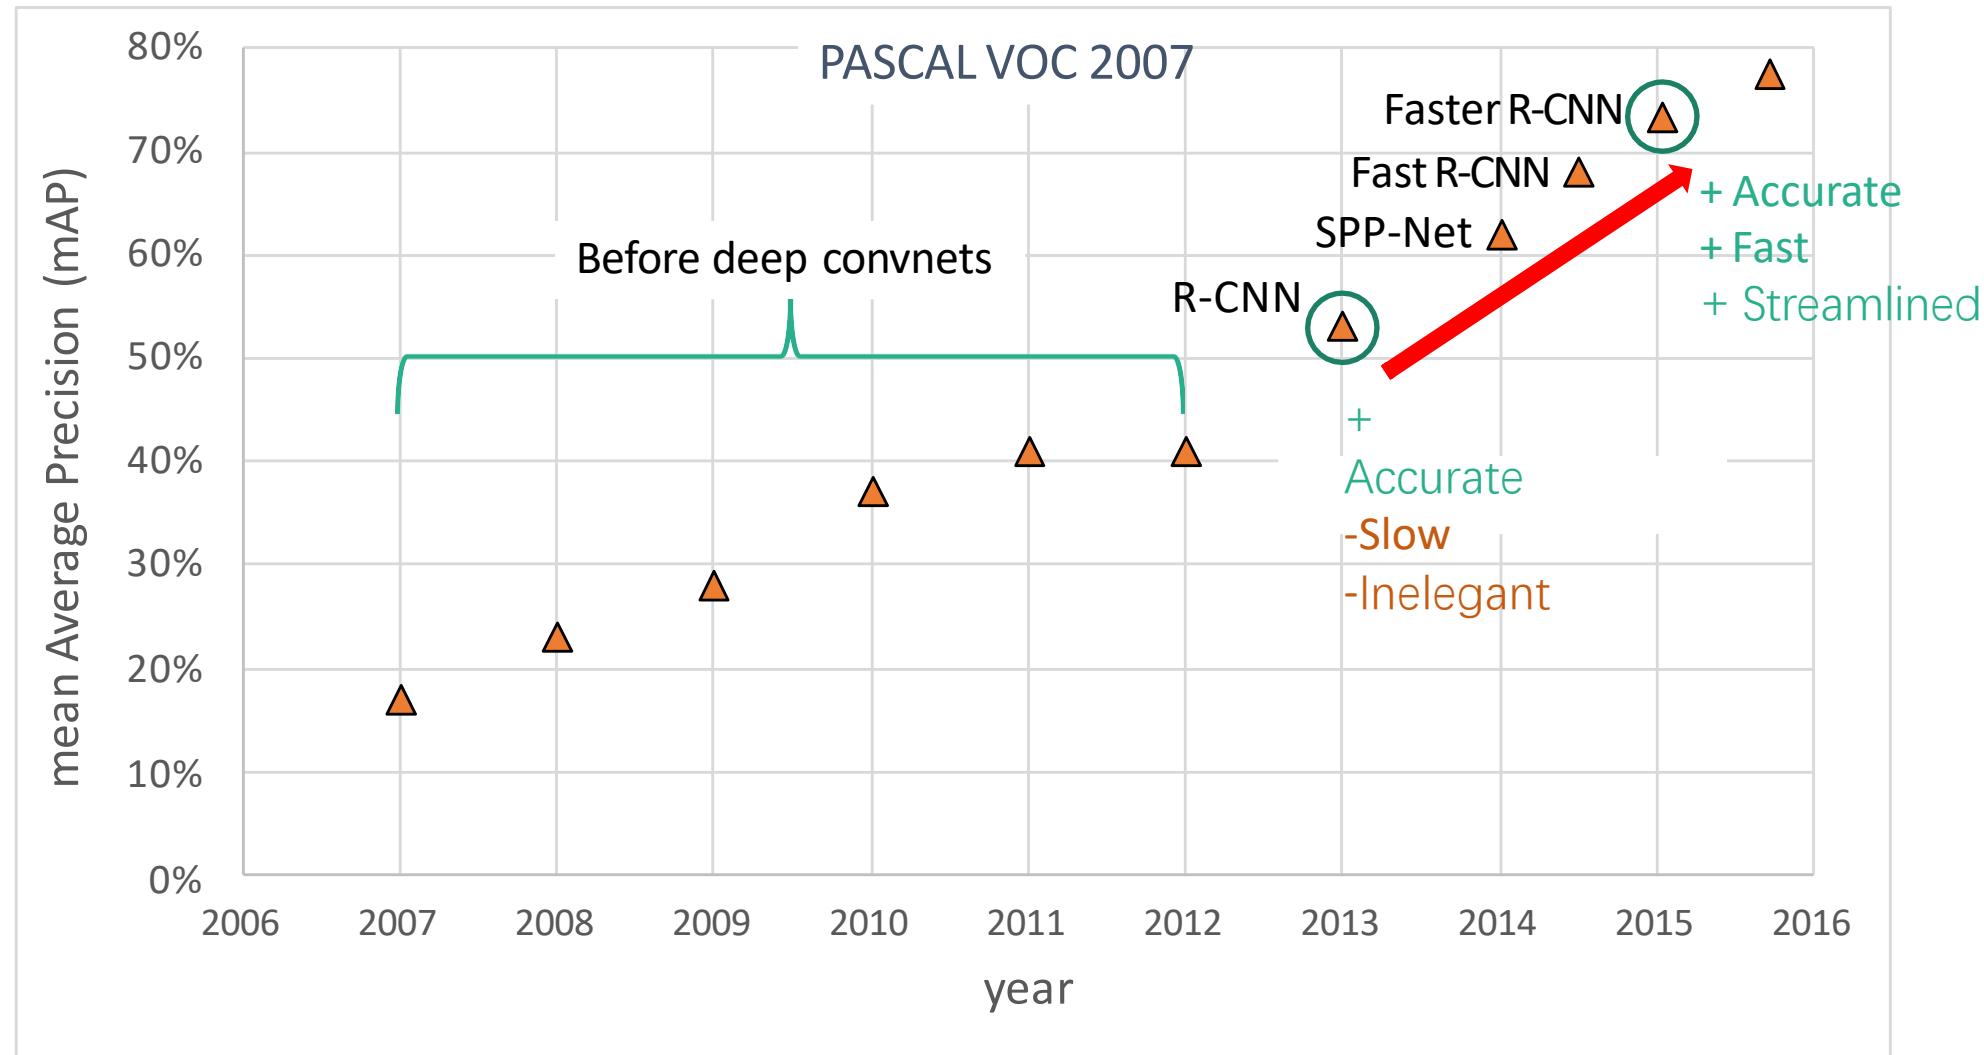
目标识别—object recognition

COCO Examples



目标识别—object recognition

目标识别发展过程



目标识别—object recognition

3个典型工作: R-CNN SPP NET Fast R-CNN Faster RCNN

标题	引用次数	发表年份
Object detection with discriminatively trained part-based models PF Felzenszwalb, RB Girshick, D McAllester, D Ramanan Pattern Analysis and Machine Intelligence, IEEE Transactions on 32 (9), 1627 ...	4457	2010
Caffe: Convolutional architecture for fast feature embedding Y. Jia, E. Shelhamer, J. Donahue, S. Karayev, J. Long, R. Girshick, ... Proceedings of the 22nd ACM international conference on Multimedia, 675-678	2306	2014
Rich feature hierarchies for accurate object detection and semantic segmentation R. Girshick, J. Donahue, T. Darrell, J. Malik Proceedings of the IEEE conference on computer vision and pattern ...	1753	2014
Cascade object detection with deformable part models PF Felzenszwalb, RB Girshick, D McAllester Computer vision and pattern recognition (CVPR), 2010 IEEE conference on ...	500	2010
Fast r-cnn R. Girshick Proceedings of the IEEE International Conference on Computer Vision, 1440-1448	344	2015
Discriminatively Trained Deformable Part Models (DPM) Code RB Girshick, PF Felzenszwalb, D McAllester http://www.cs.berkeley.edu/~rgb/latent/	342 *	2012
Faster R-CNN: Towards real-time object detection with region proposal networks S. Ren, K. He, R. Girshick, J. Sun Advances in neural information processing systems, 91-99	286	2015



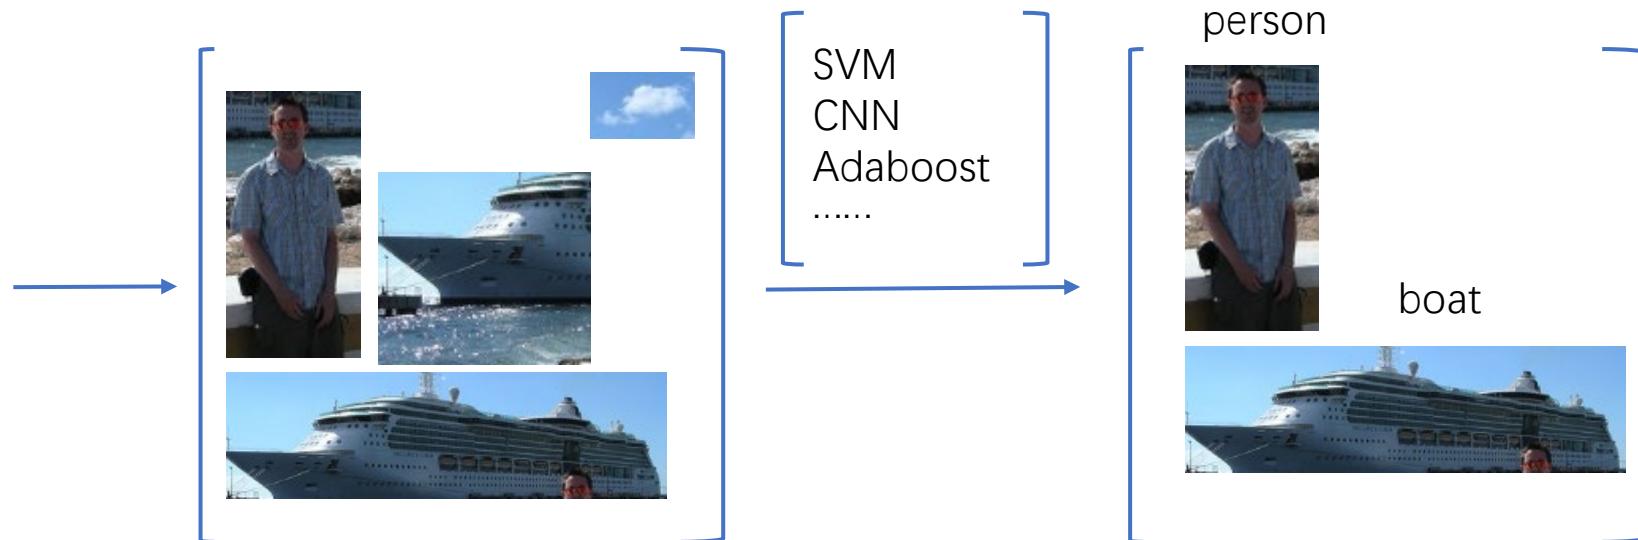
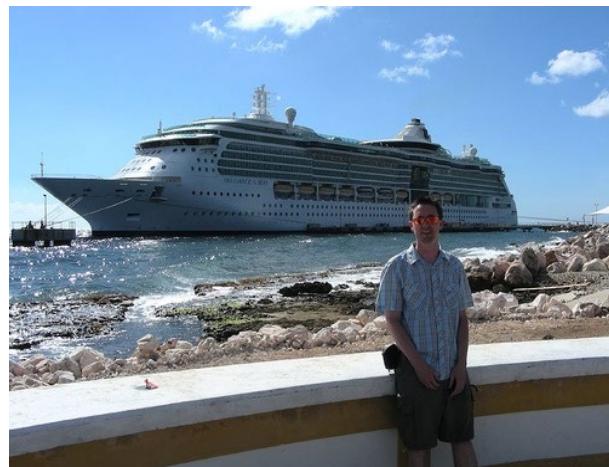
Ross Girshick

Research Scientist, Facebook AI Research (FAIR)
computer vision, machine learning
在 eeecs.berkeley.edu 的电子邮件经过验证 - 首页

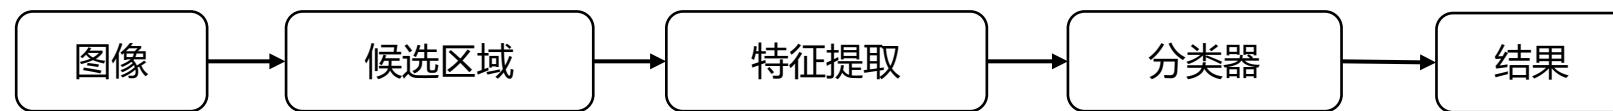
- ✓ 目标识别介绍
- ✓ 传统方法和深度学习对比
- ✓ Faster RCNN介绍
- ✓ Faster RCNN代码详解

目标识别—object recognition

目标识别流程



算法流程



➤ 候选区域提取

基于学习：BING, EdgeBoxes

基于区域：海陆分割，机场检测

基于模板：模板匹配

➤ 特征提取：颜色、纹理、HOG等

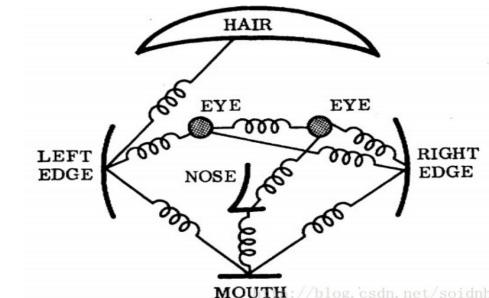
➤ 分类器：SVM、Adaboost等

主流框架：

词袋模型



可变部件模型



模板匹配



相关工作介绍—传统方法DPM

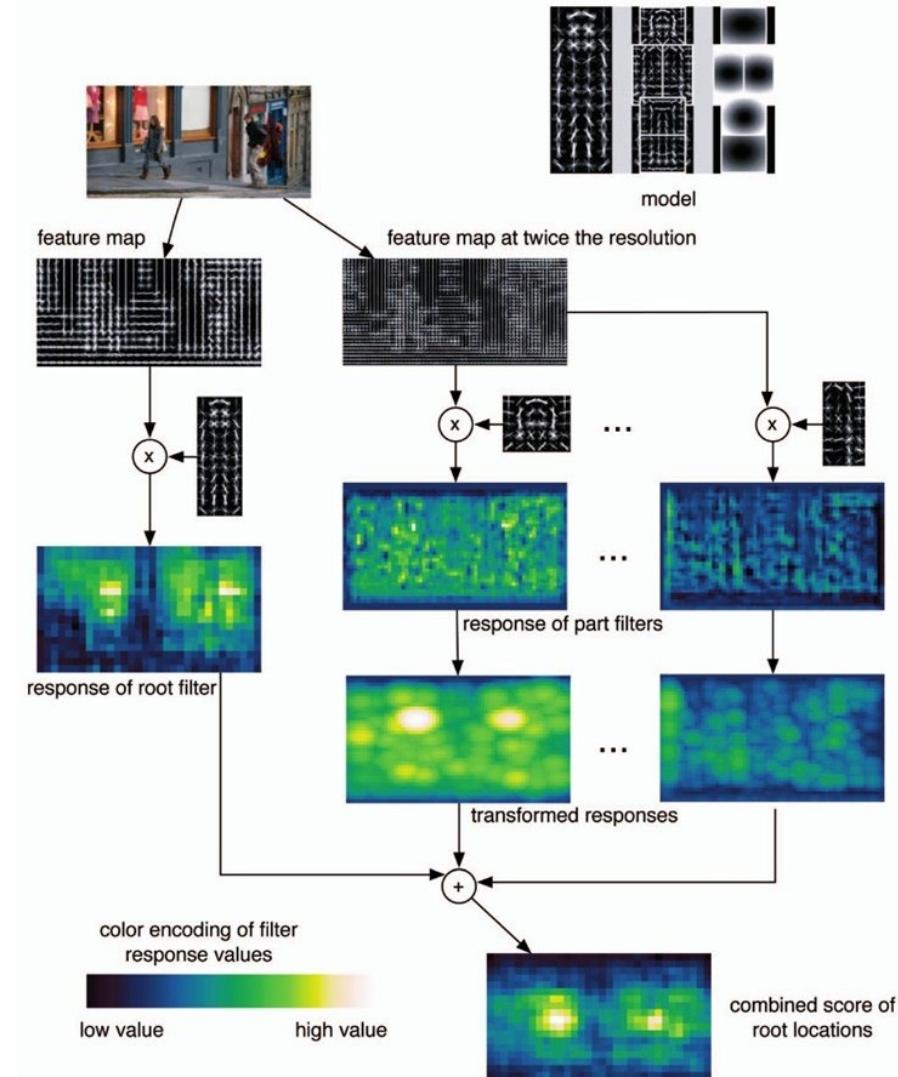
Deformable Parts Model(DPM):

获得VOC (Visual Object Class) 07,08,09年的检测冠军。

2010年Pedro Felzenszwalb被VOC授予“终身成就奖”

每一类都构建部件模型，以检测人体为例：

- 构建 root 滤波器—人体
- 构建 part 滤波器—头，四肢
- 构建能量函数
- 在大图中滑动检测



相关工作介绍—深度学习

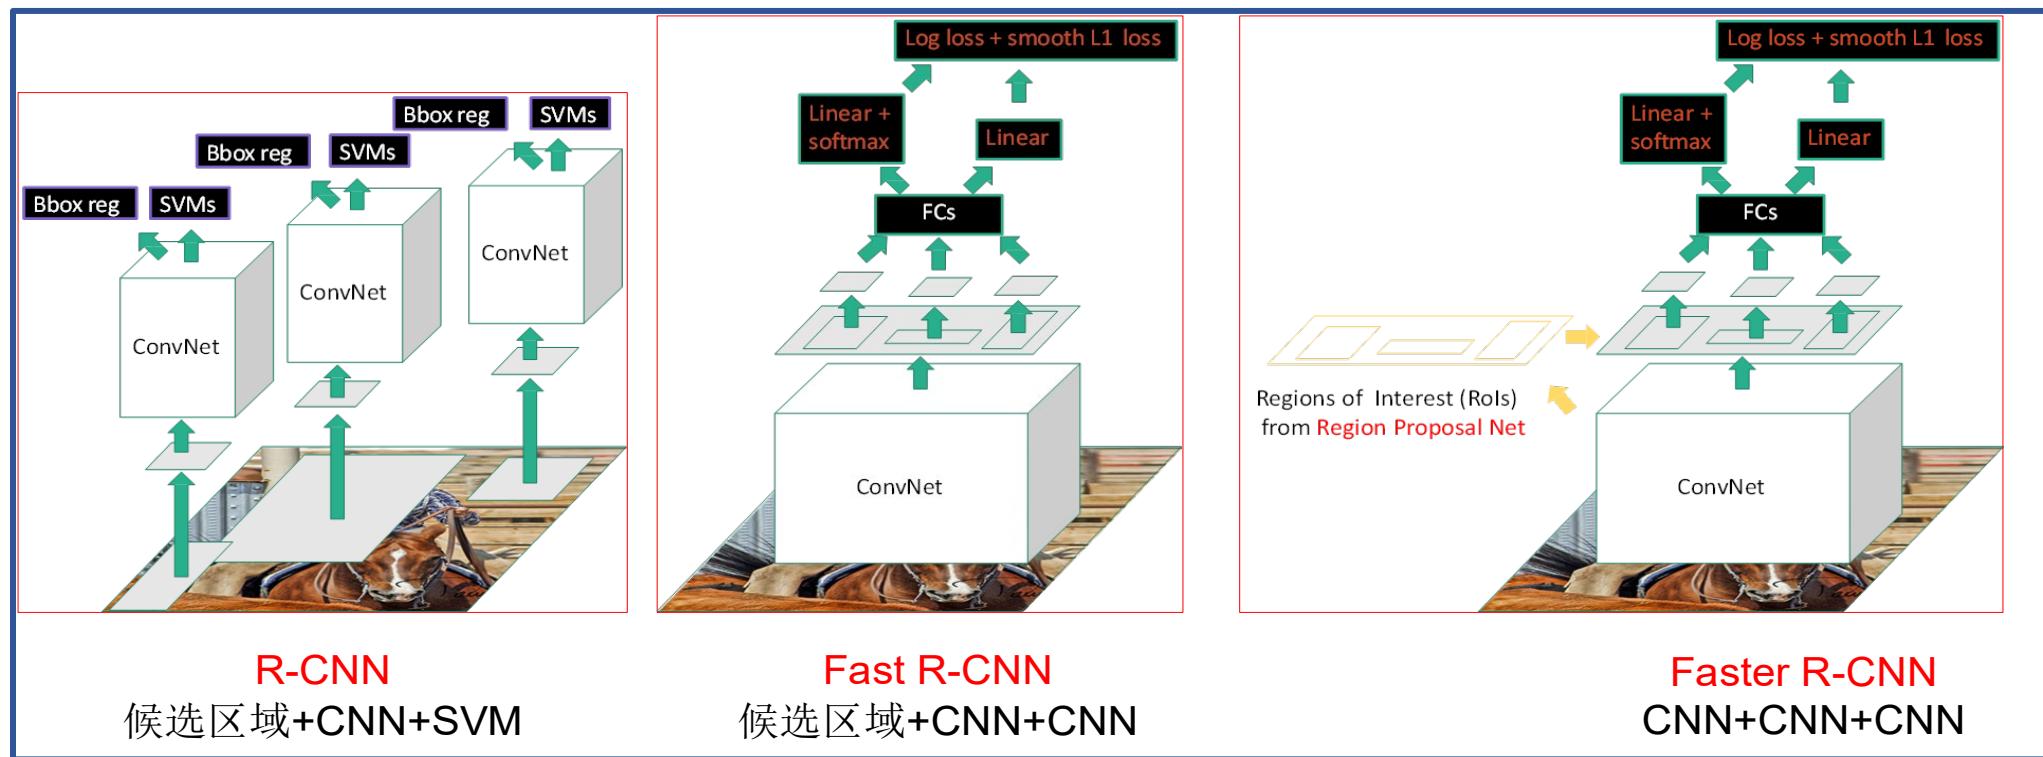
算法流程

➤ 基于区域：

R-CNN CVPR2014

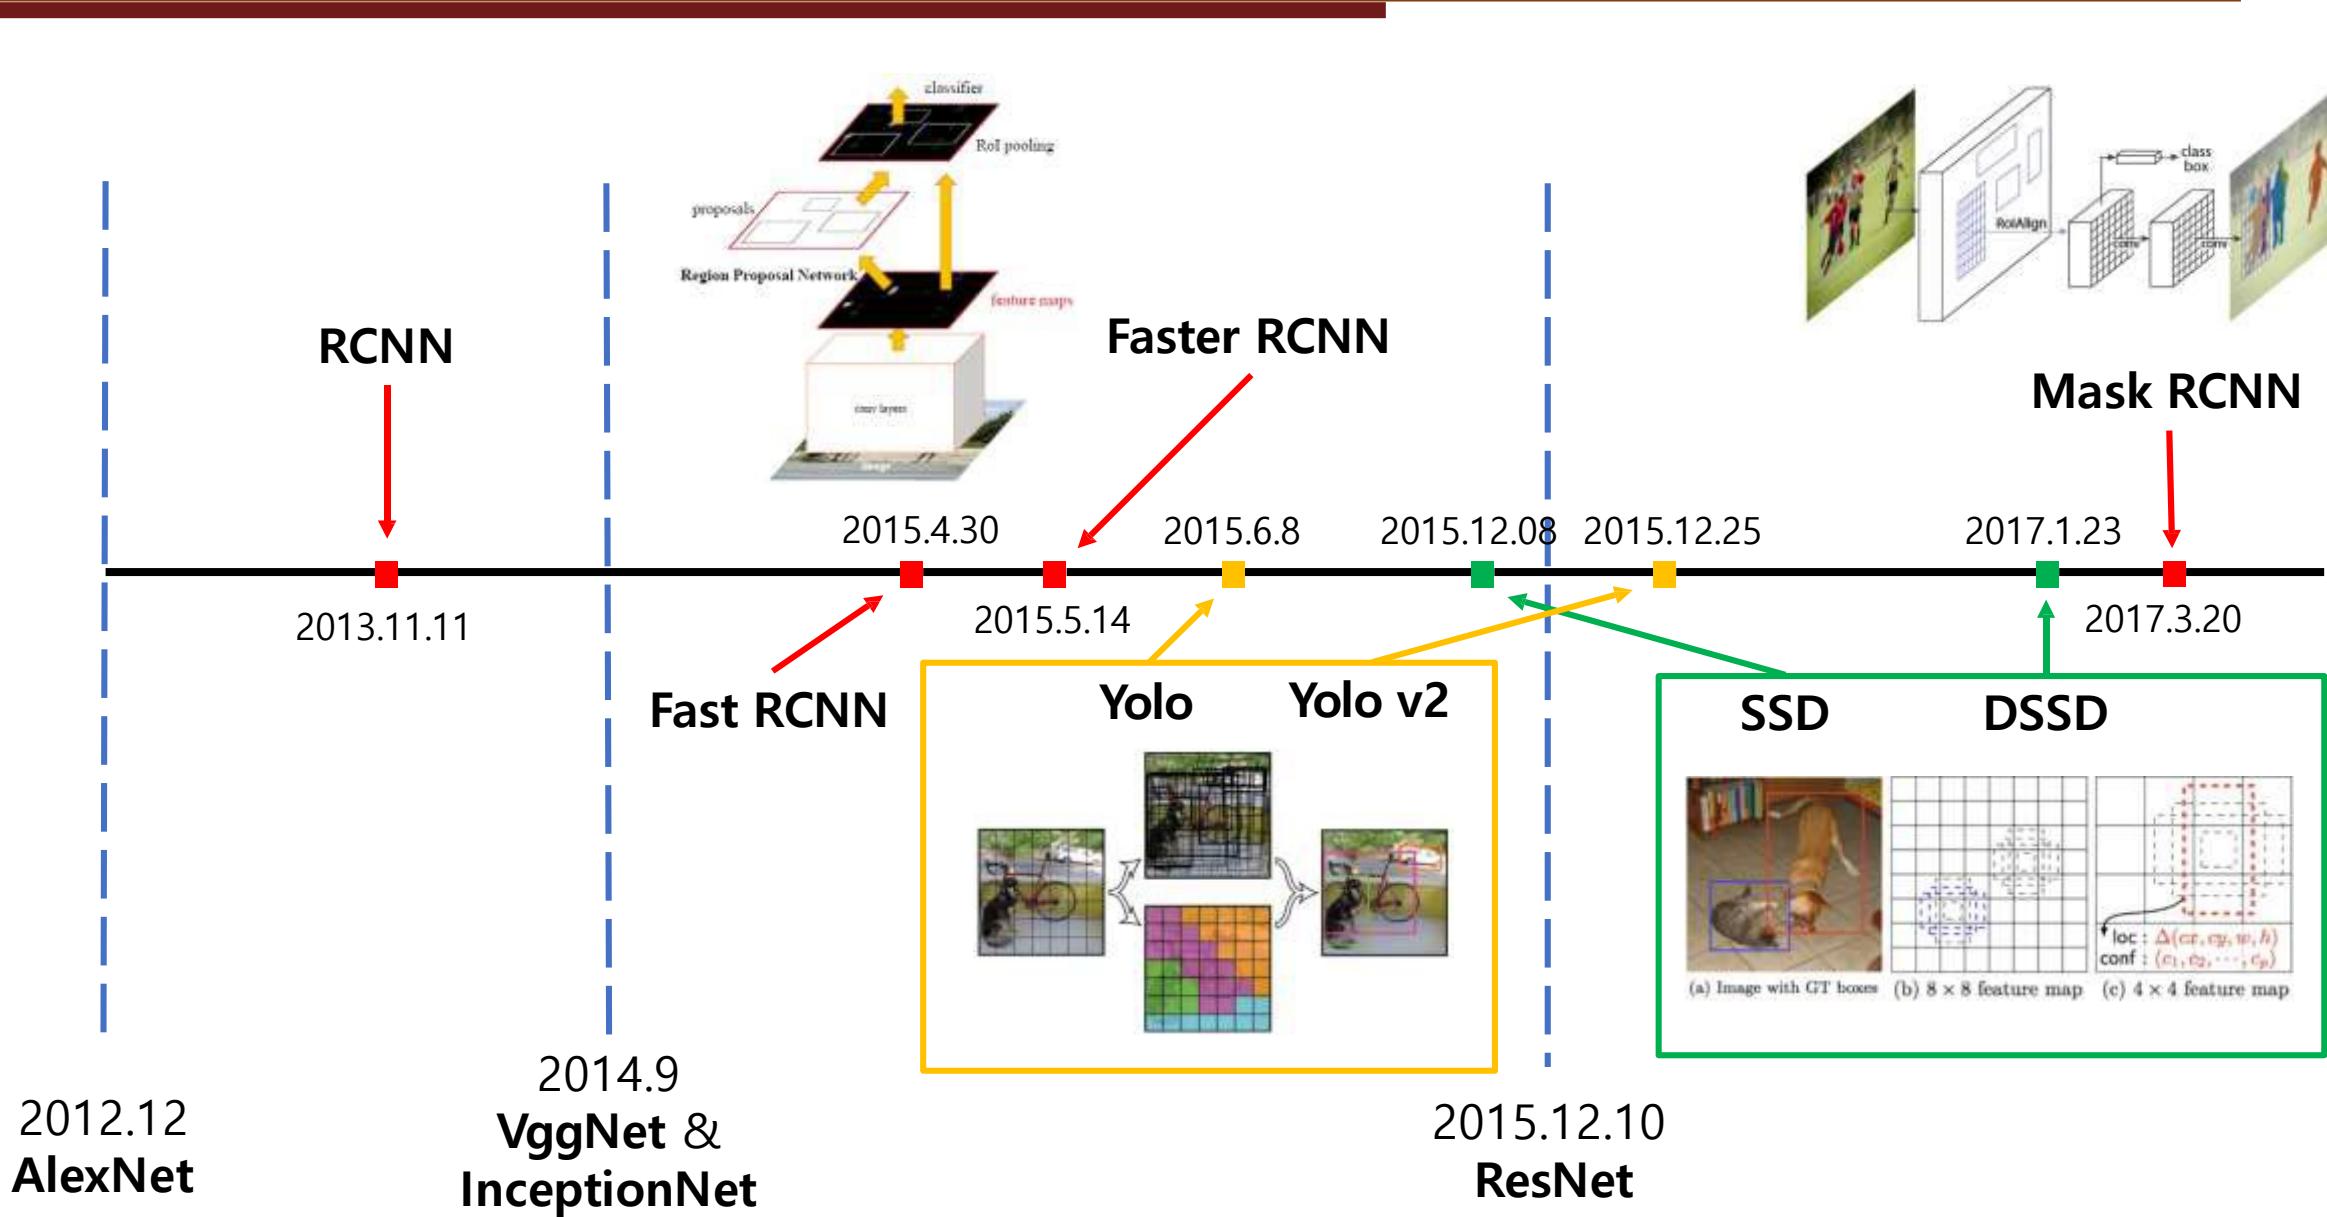
Fast R-CNN ECCV2014

Faster R-CNN NIPS2015

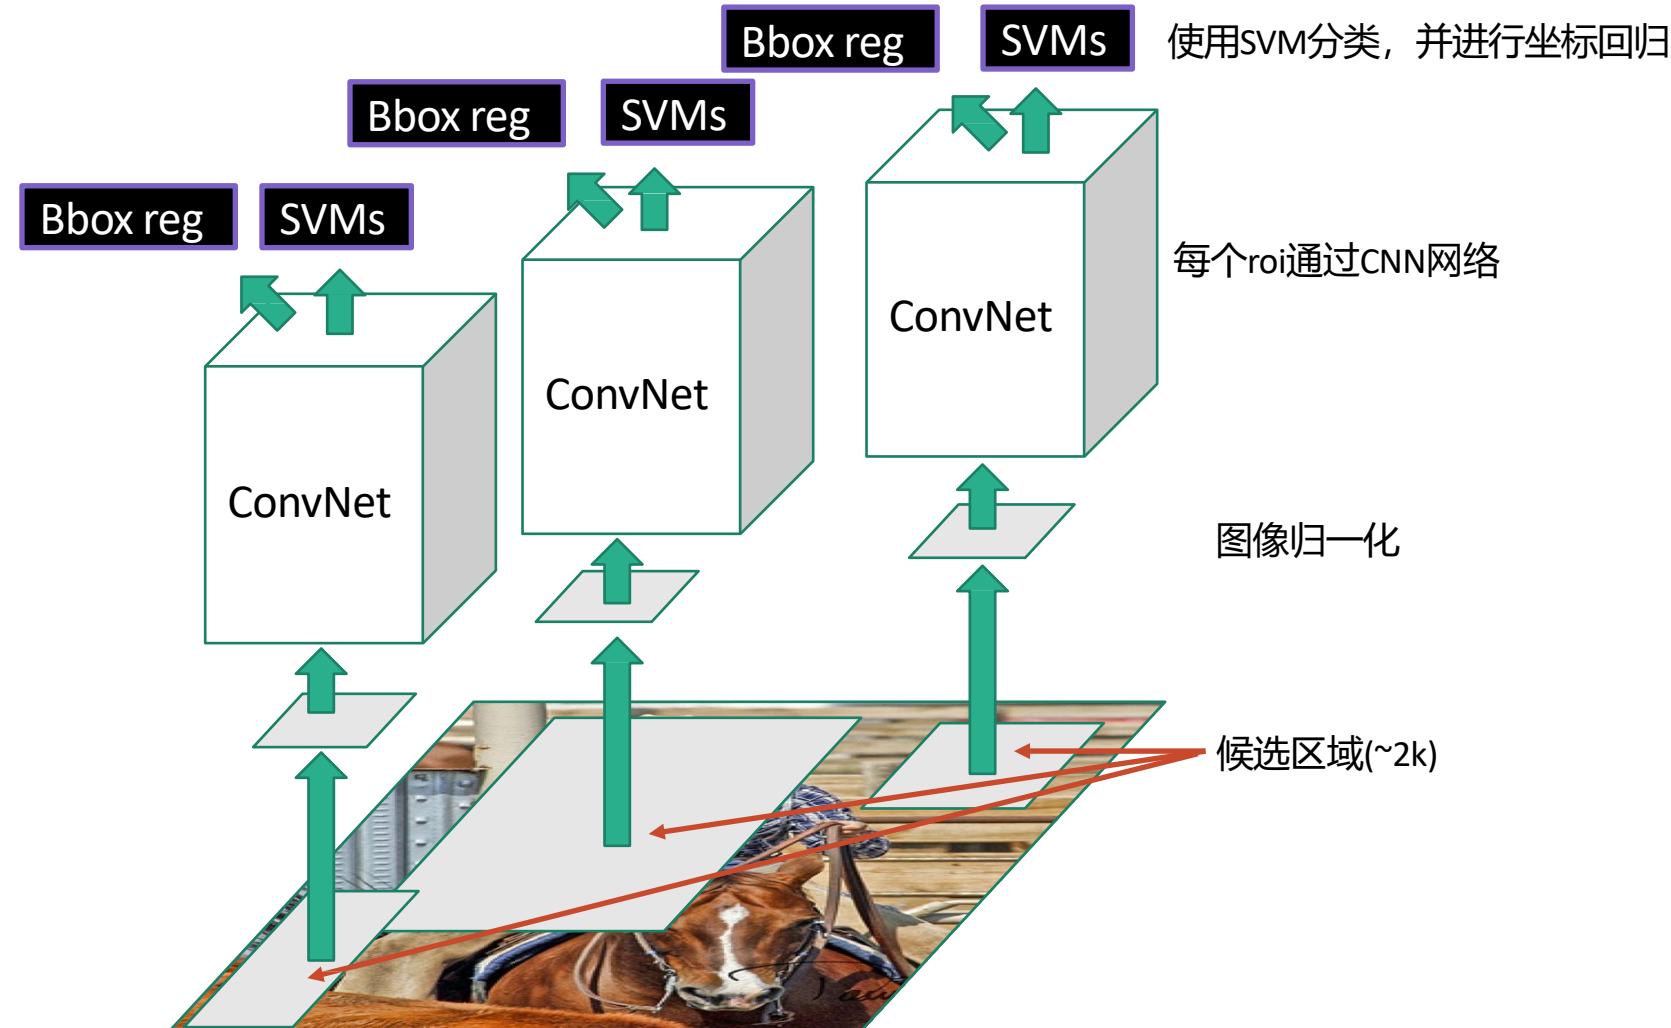


- 基于回归: YOLO CVPR2016, SSD ECCV2016
- 基于RNN: IONet CVPR2016

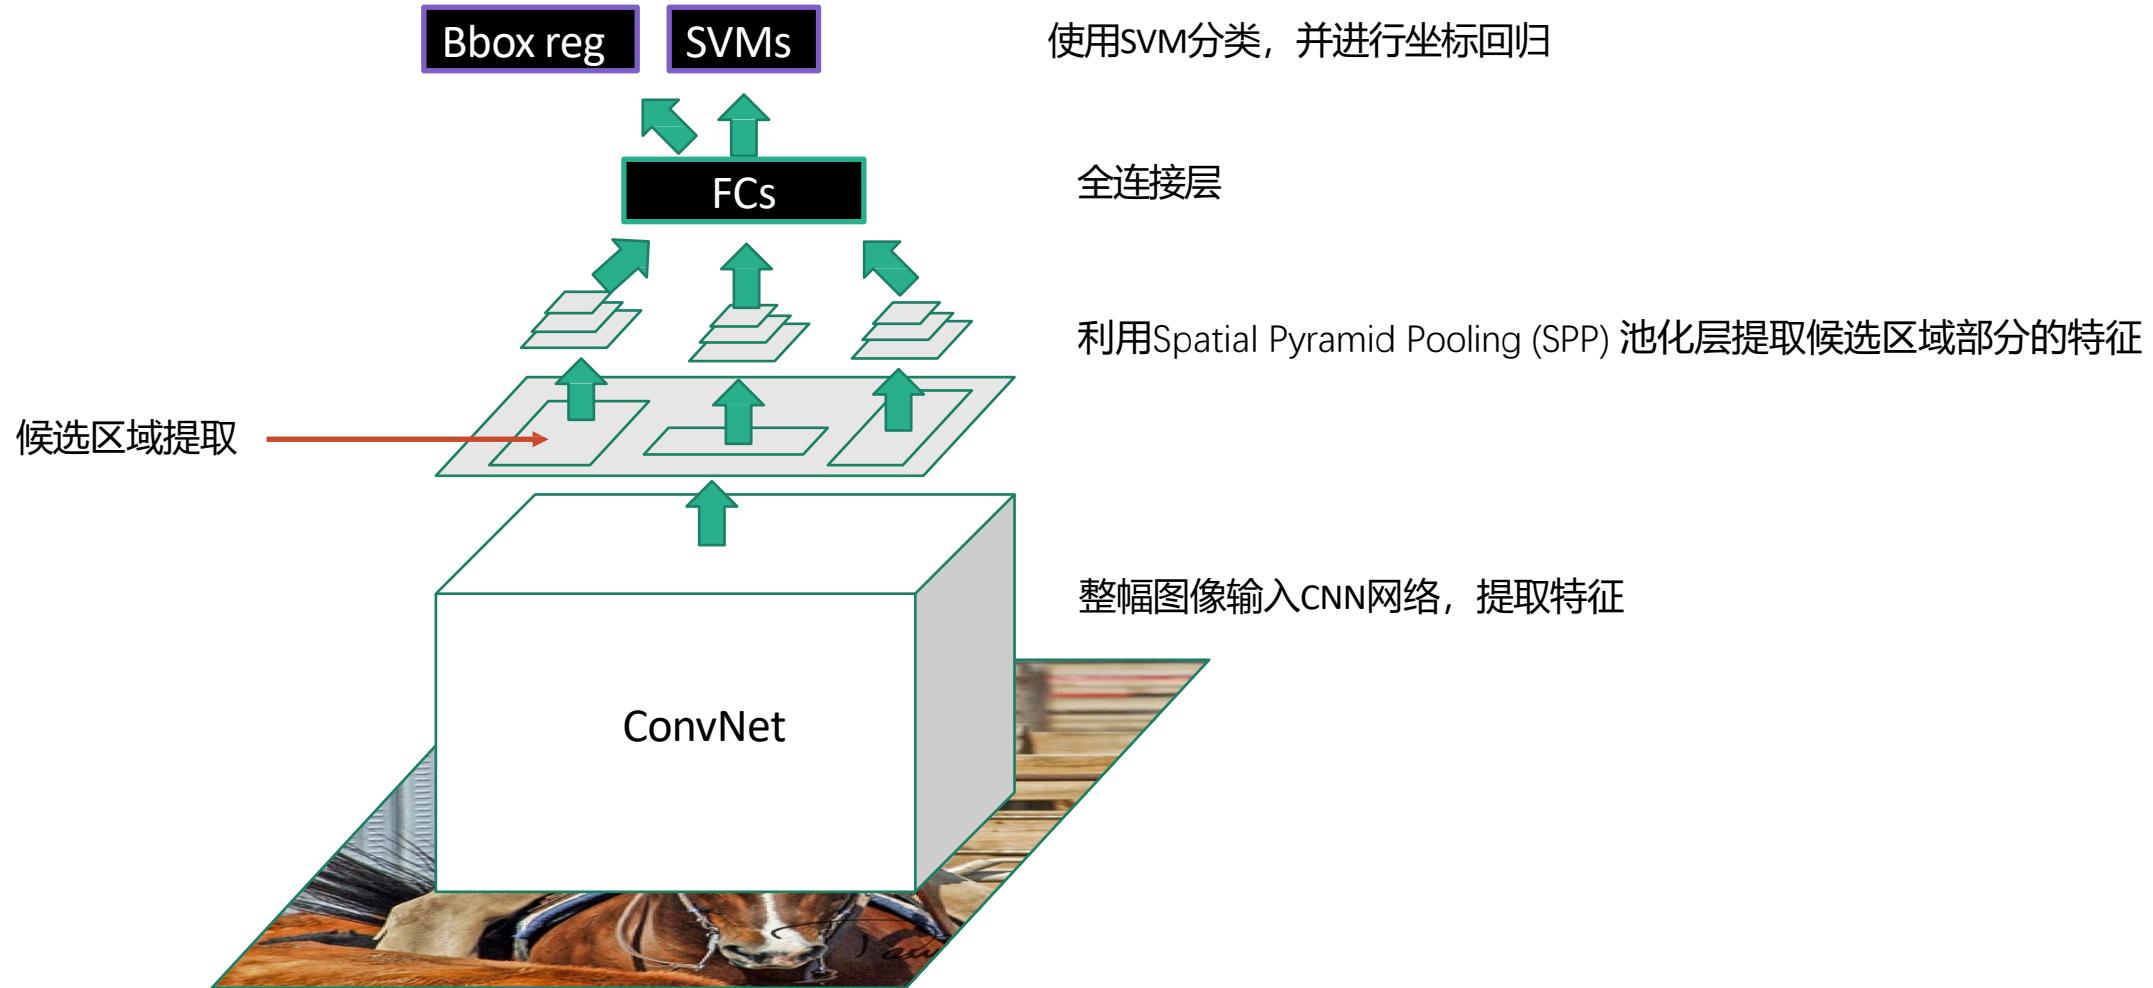
相关工作介绍—深度学习



相关工作介绍--RCNN



相关工作介绍—SPP Net

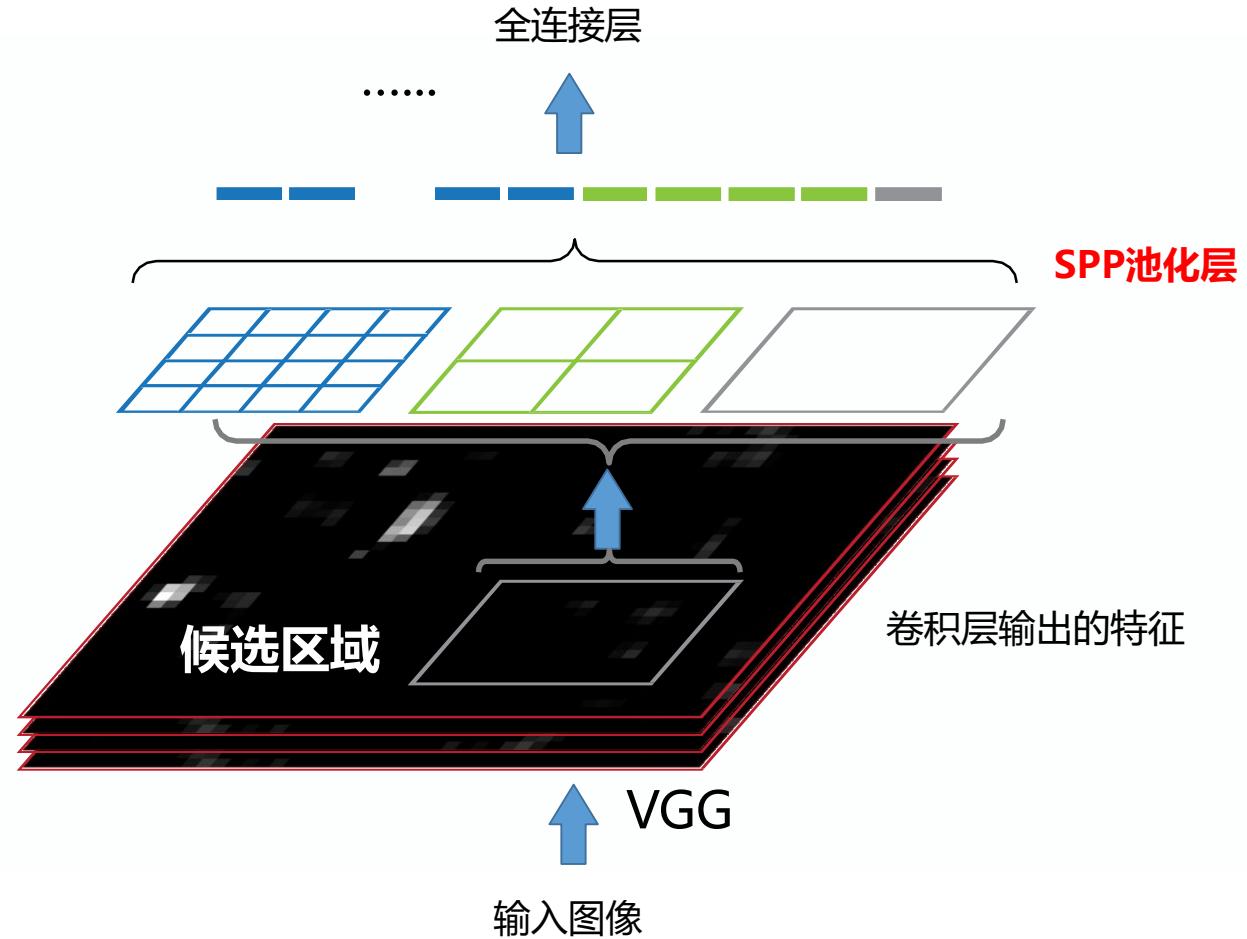


相关工作介绍—SPP Net

□ SPP池化层 (Spatial Pyramid Pooling)

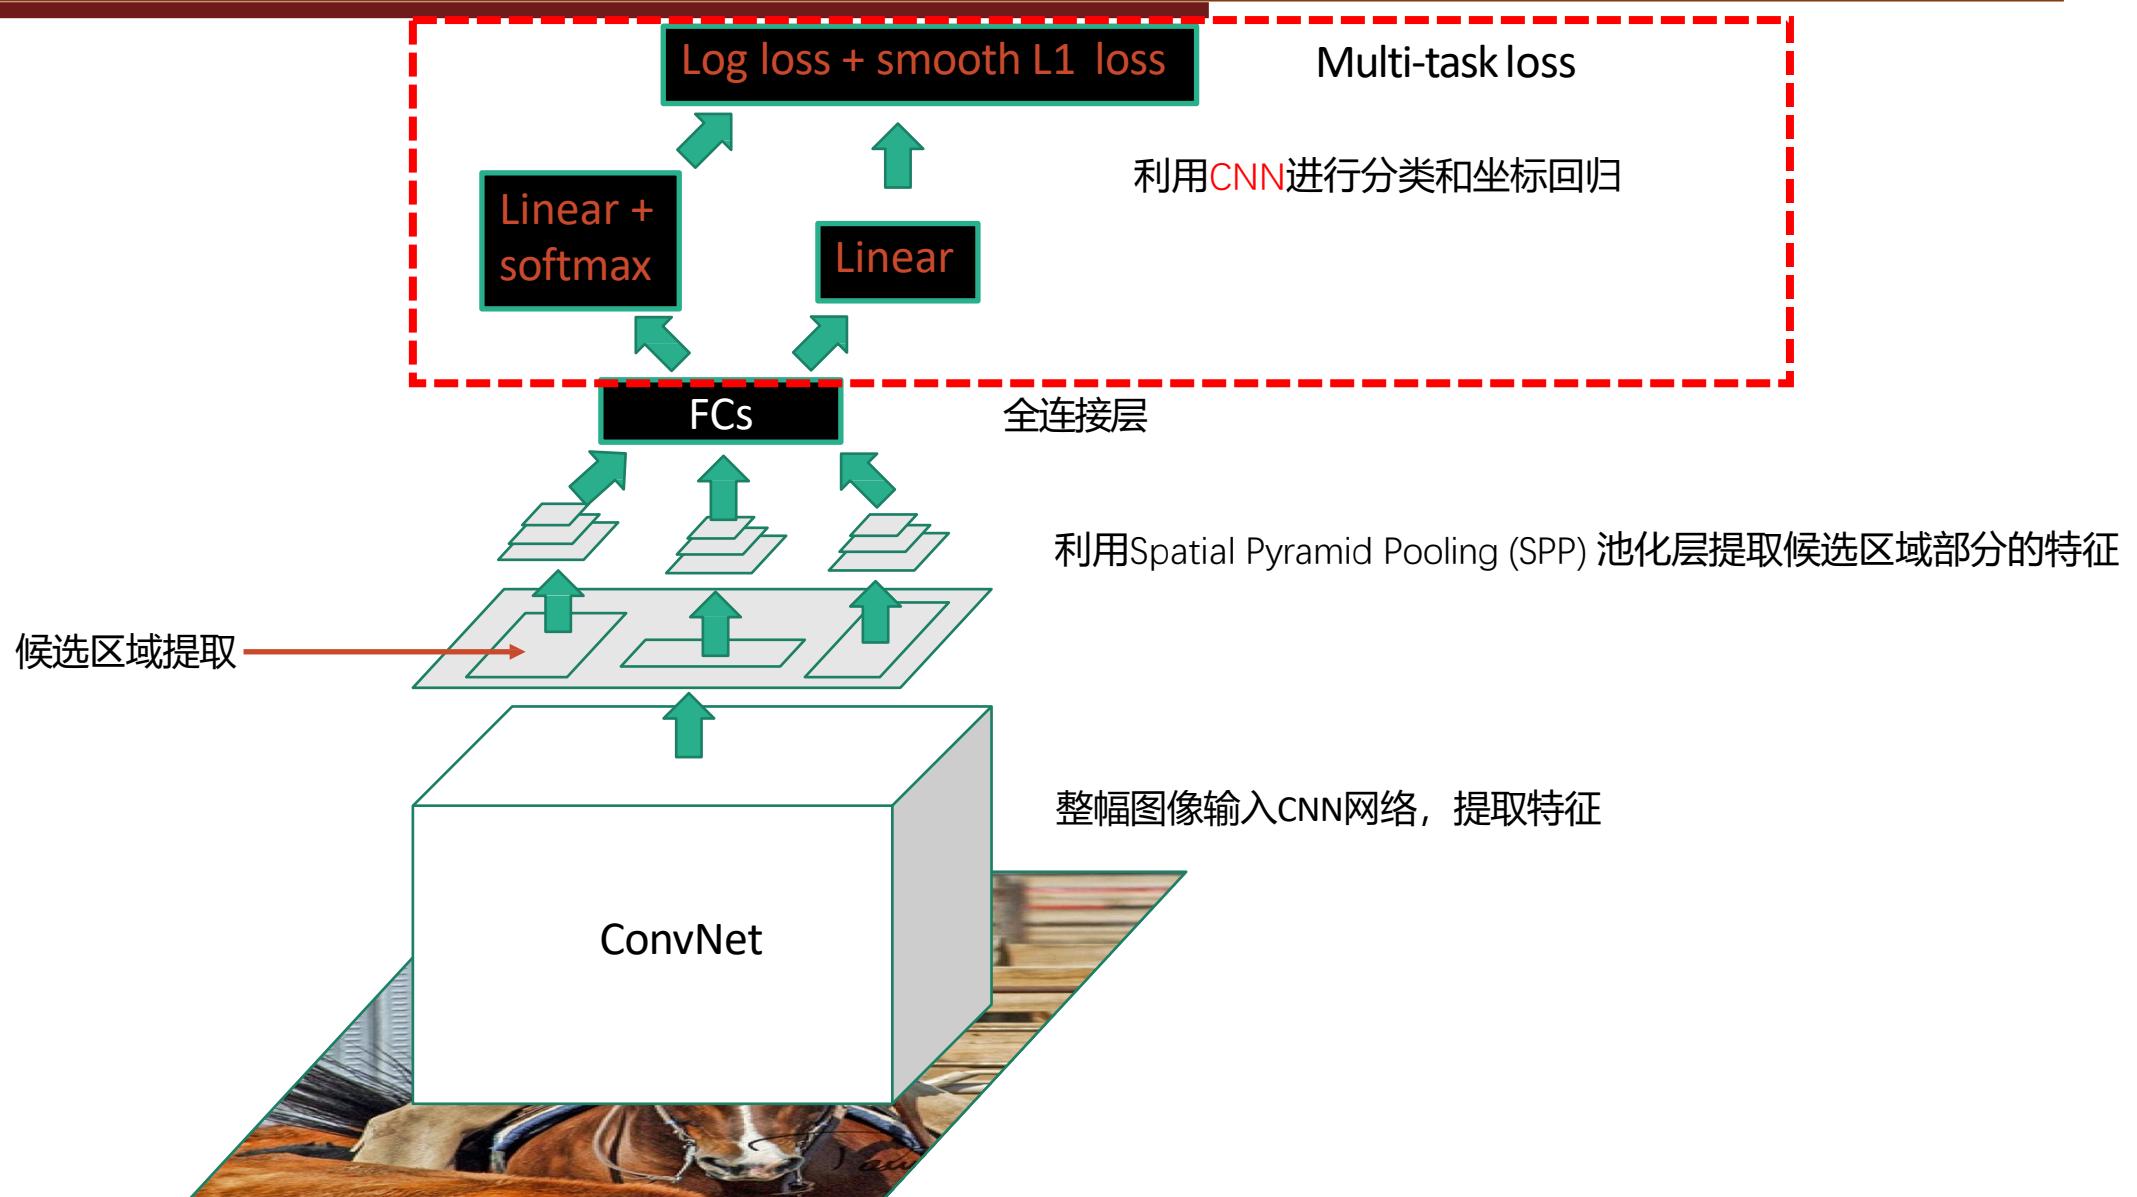
输入特征大小: $w \times h \times c$

提取后特征尺寸: $4 \times 4 \times c + 2 \times 2 \times c + 1 \times 1 \times c$

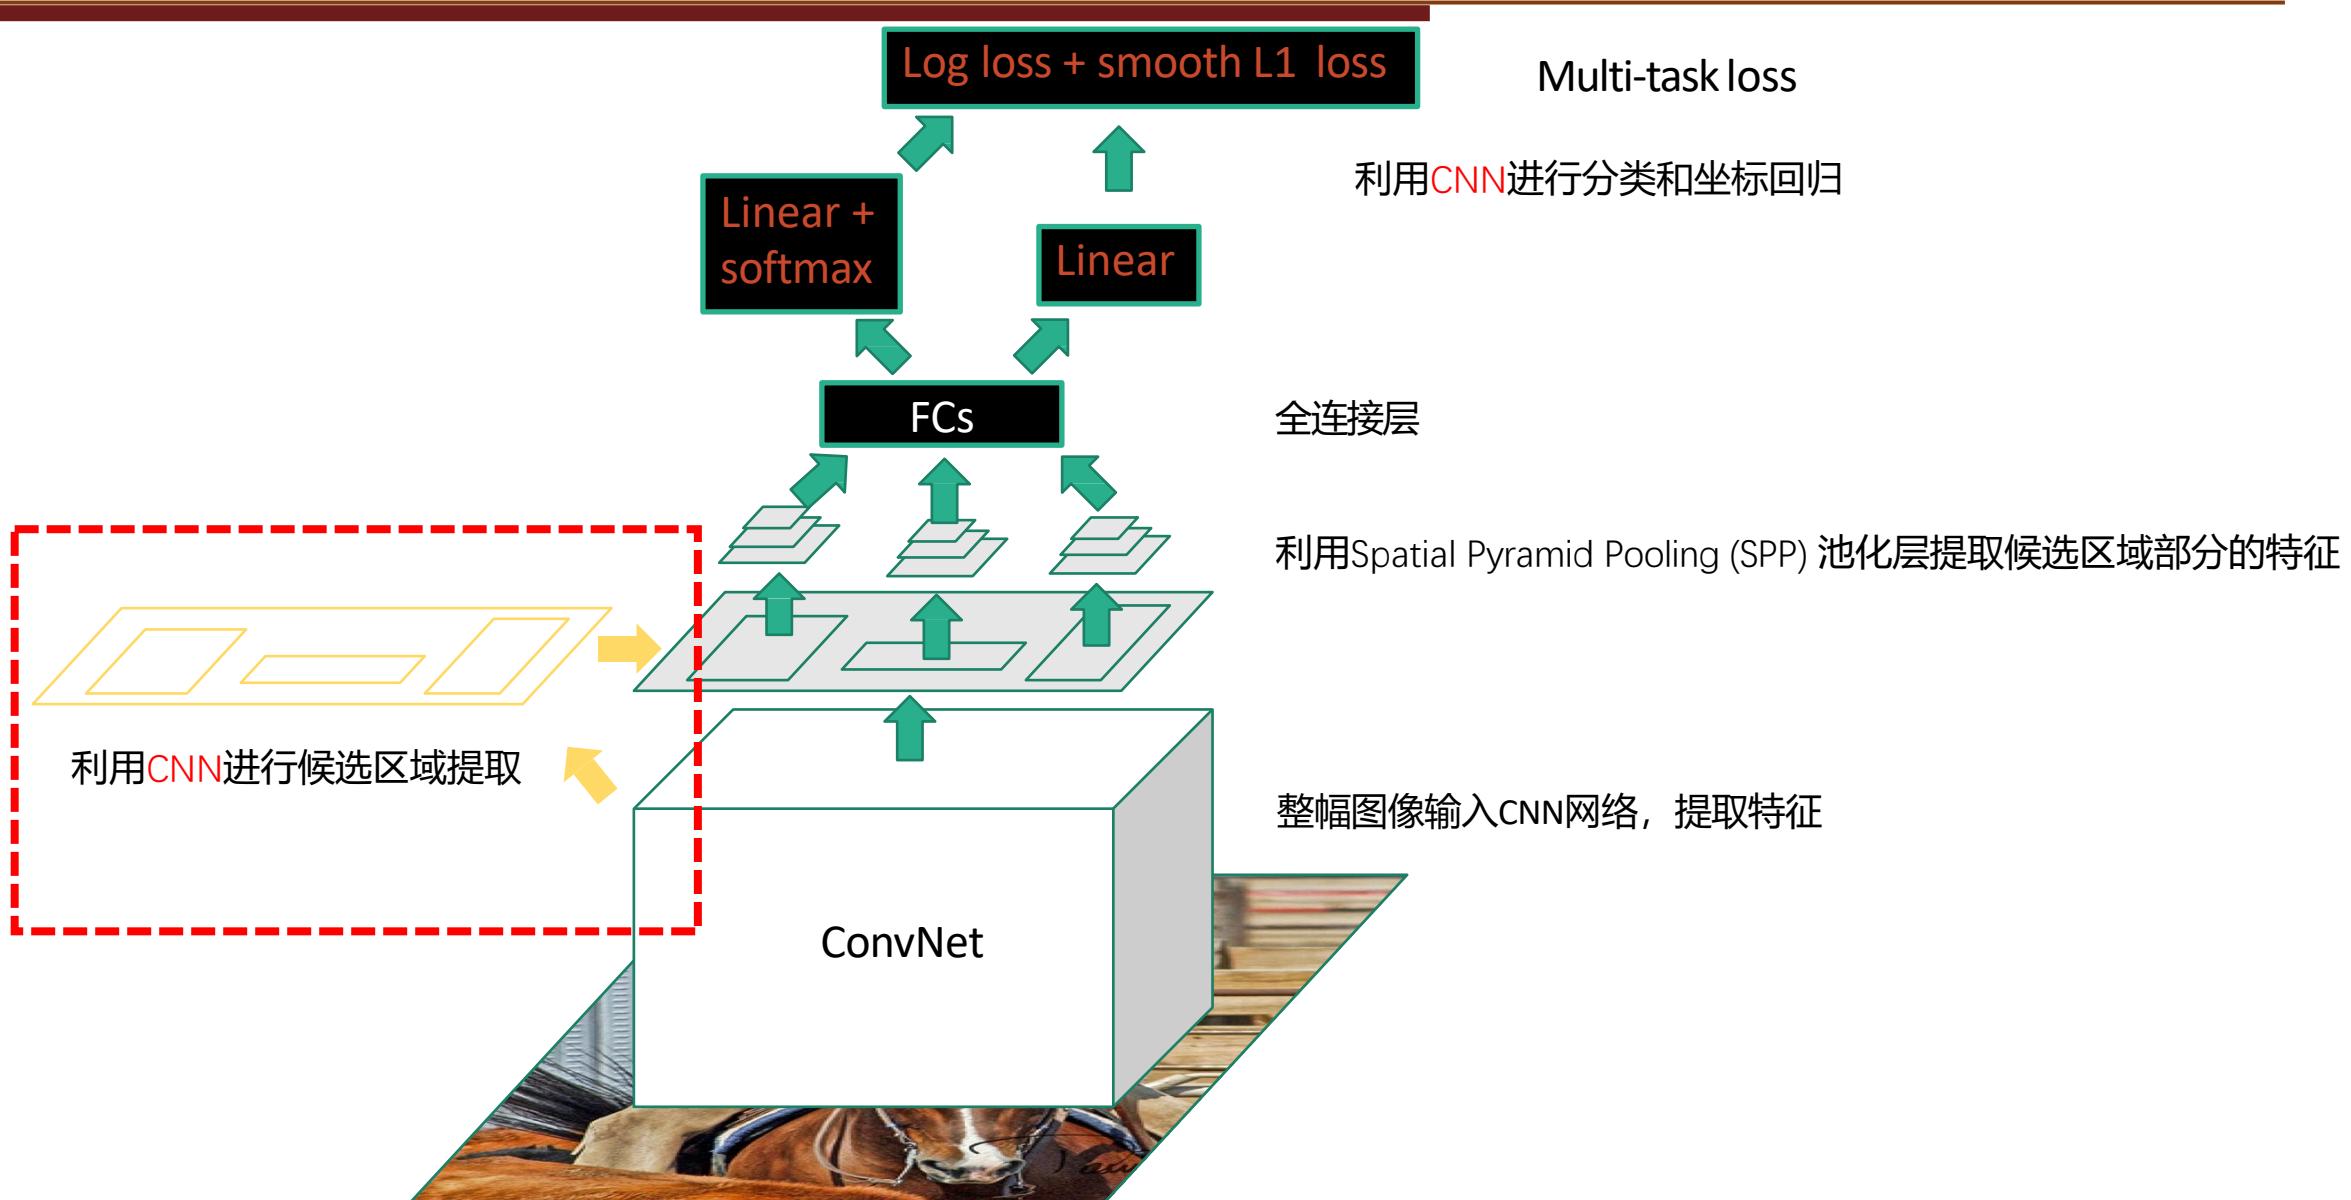


不同尺寸候选区域提取到同样维度的特征，便于输入全连接层

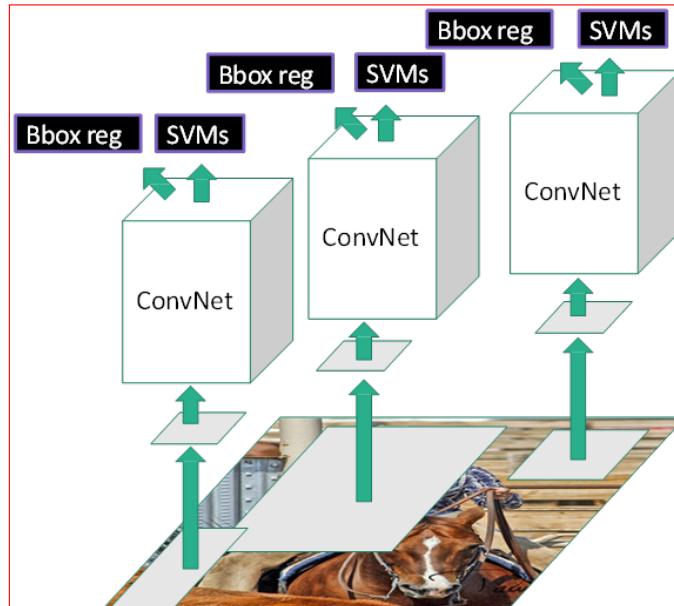
相关工作介绍—Fast RCNN



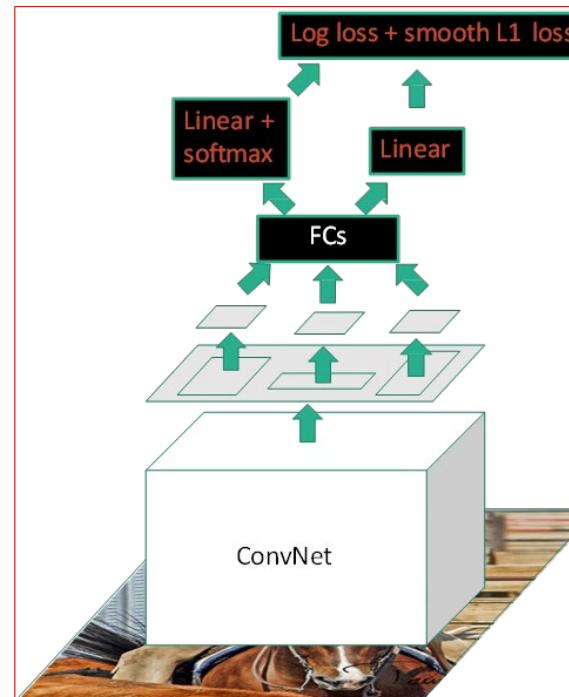
相关工作介绍—Fast RCNN



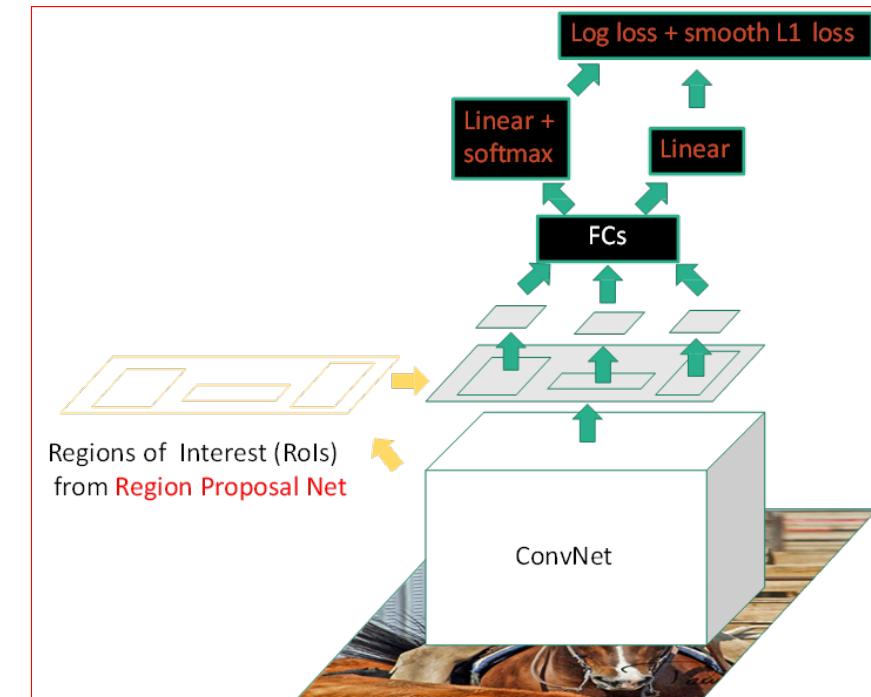
相关工作介绍—RCNN 系列



R-CNN
proposals+CNN+SVM



Fast R-CNN
proposals+CNN+CNN



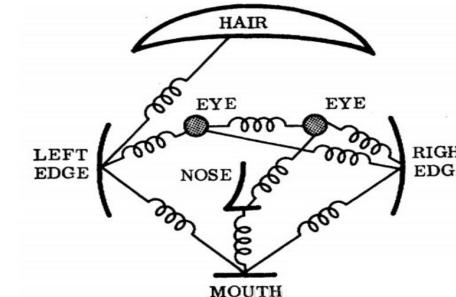
Faster R-CNN
CNN+CNN+CNN

传统方法和深度学习目标识别流程对比

词袋模型



可变部件模型



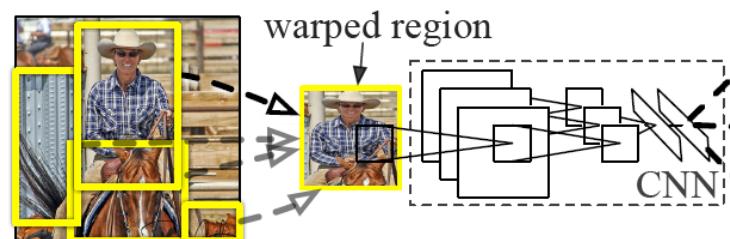
传统算法：



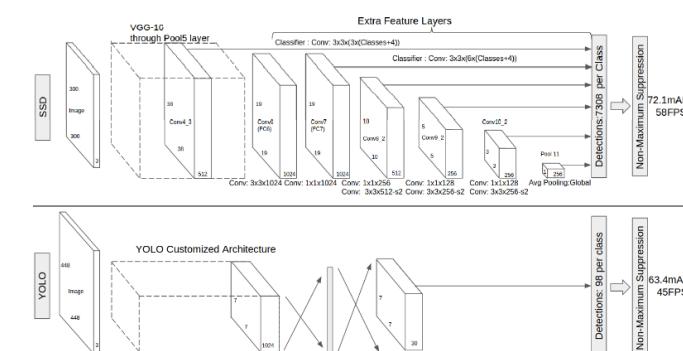
深度学习：



优点：
端到端
可塑性
普适性



R-CNN

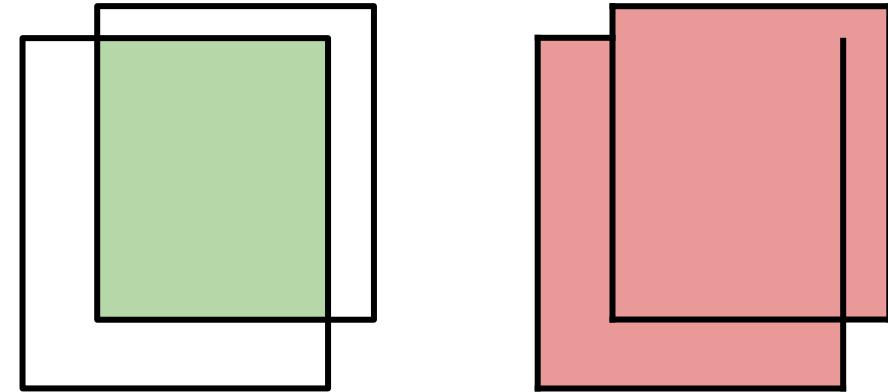


SSD, YOLO

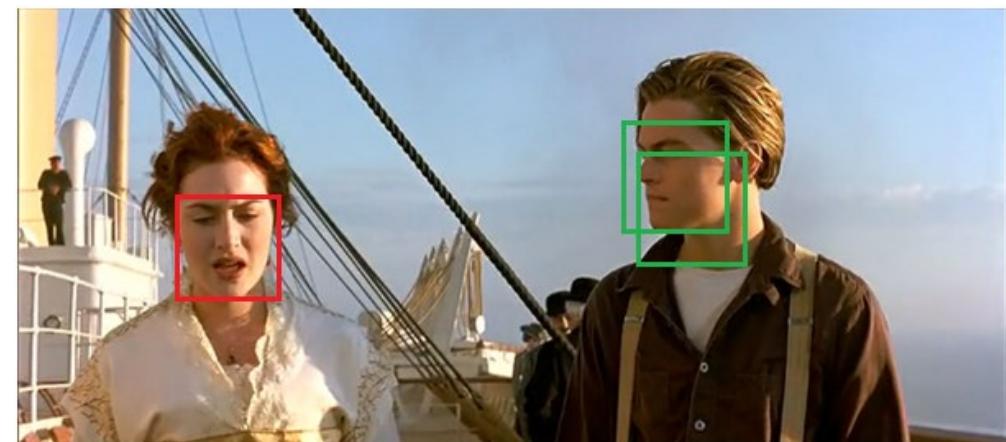
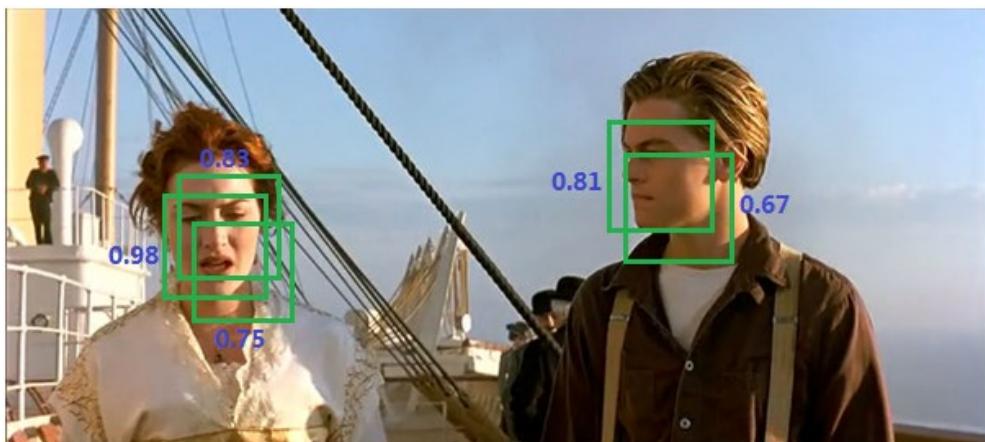
□ Intersection Over Union (IoU)

测量物体定位是否精准的测量方法

$$\text{IoU}(A,B) = \frac{\text{Intersection}(A,B)}{\text{Union}(A,B)}$$

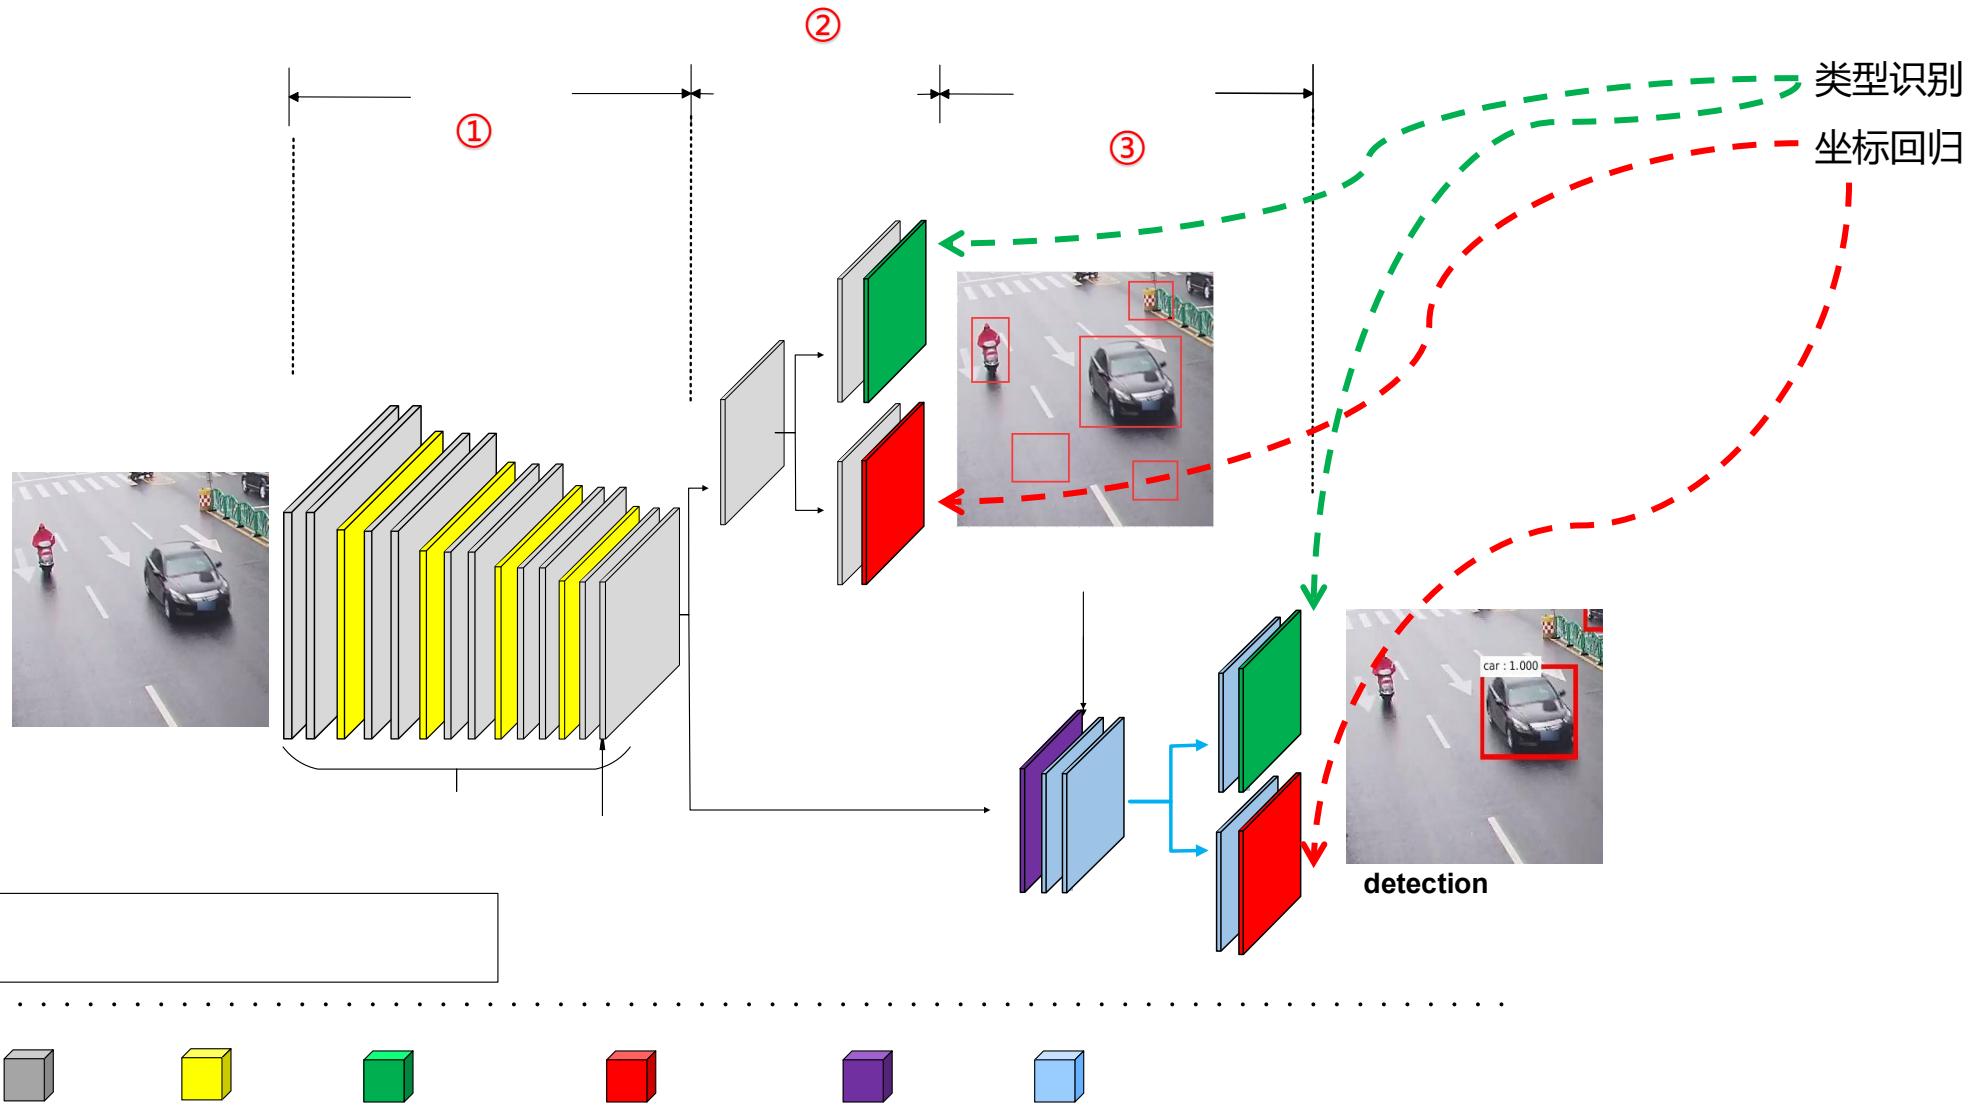


□ non maximum suppression(NMS)



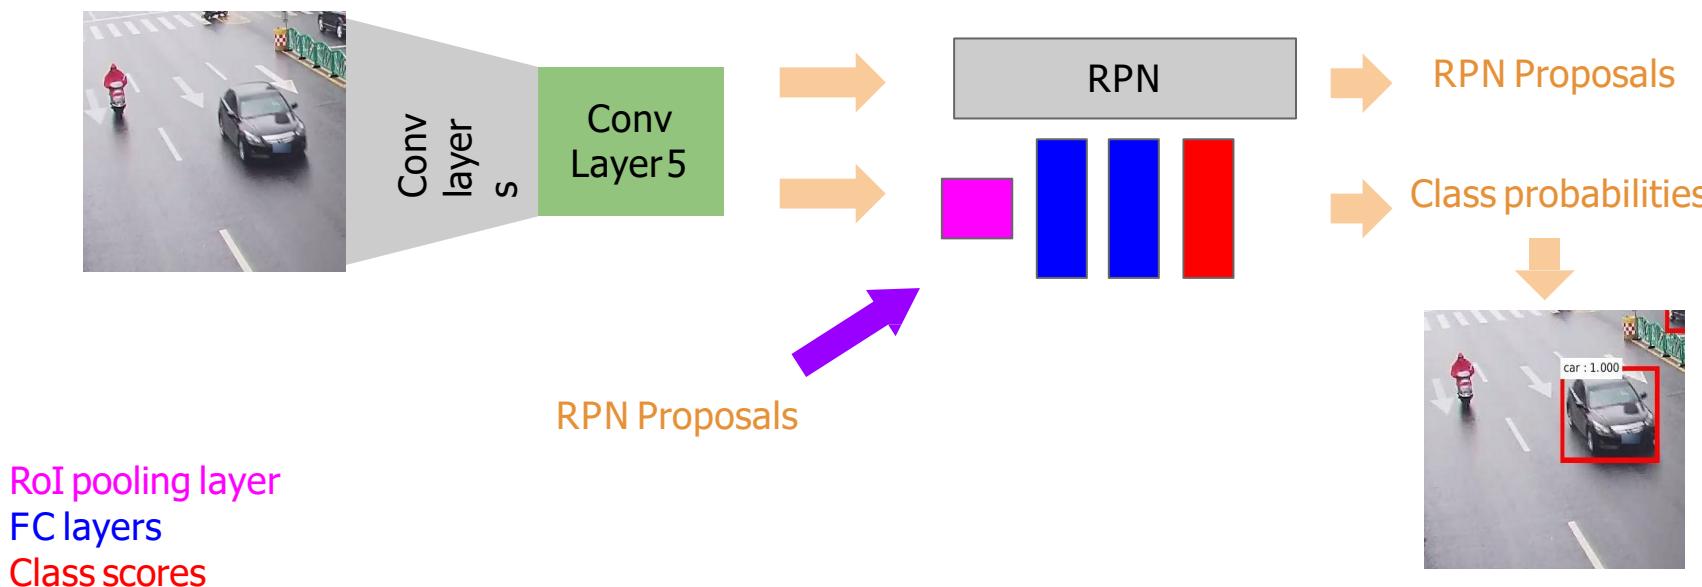
- ✓ 目标识别介绍
- ✓ 传统方法和深度学习对比
- ✓ **Faster RCNN介绍**
- ✓ **Faster RCNN代码详解**

Faster RCNN 网络结构



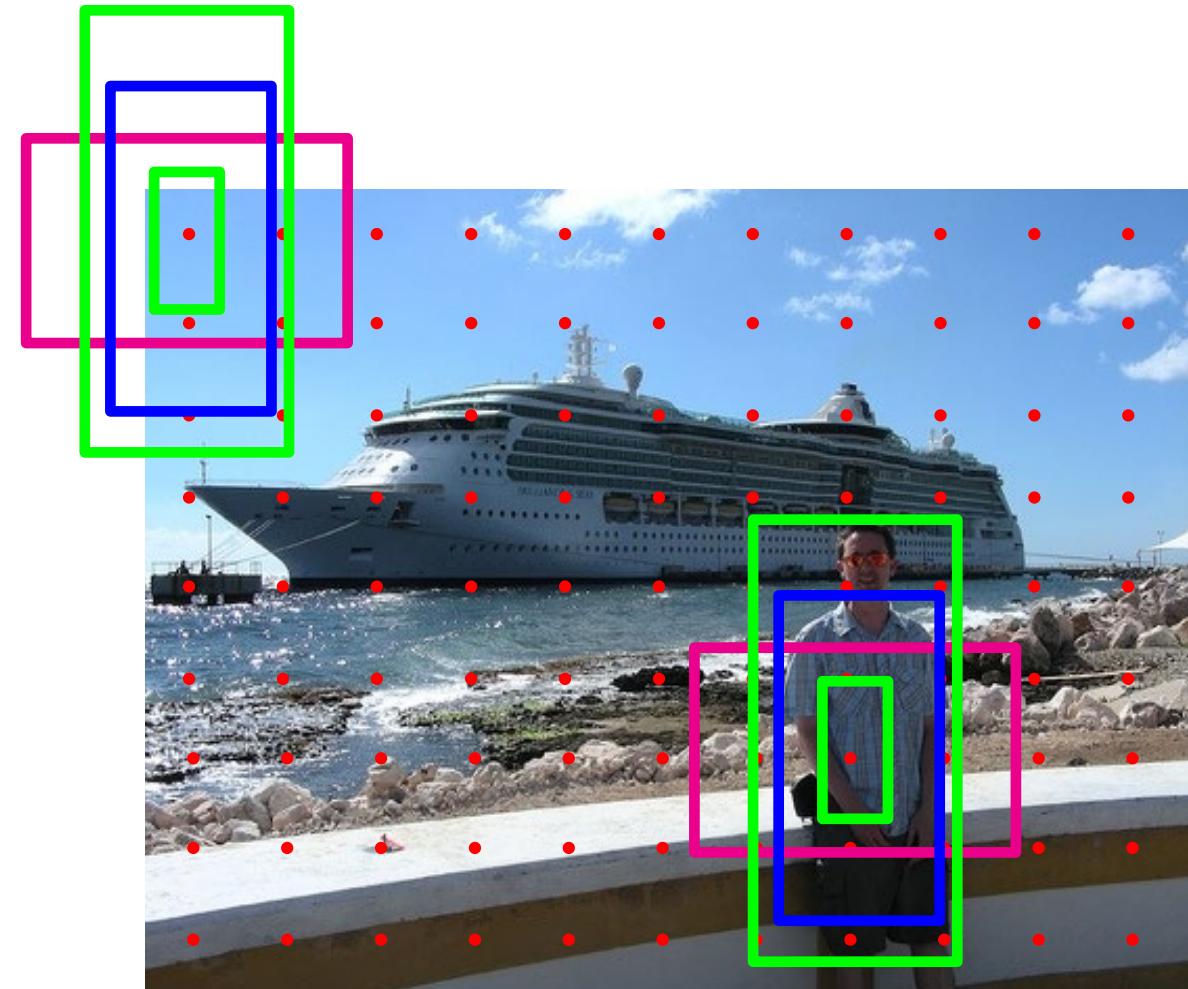
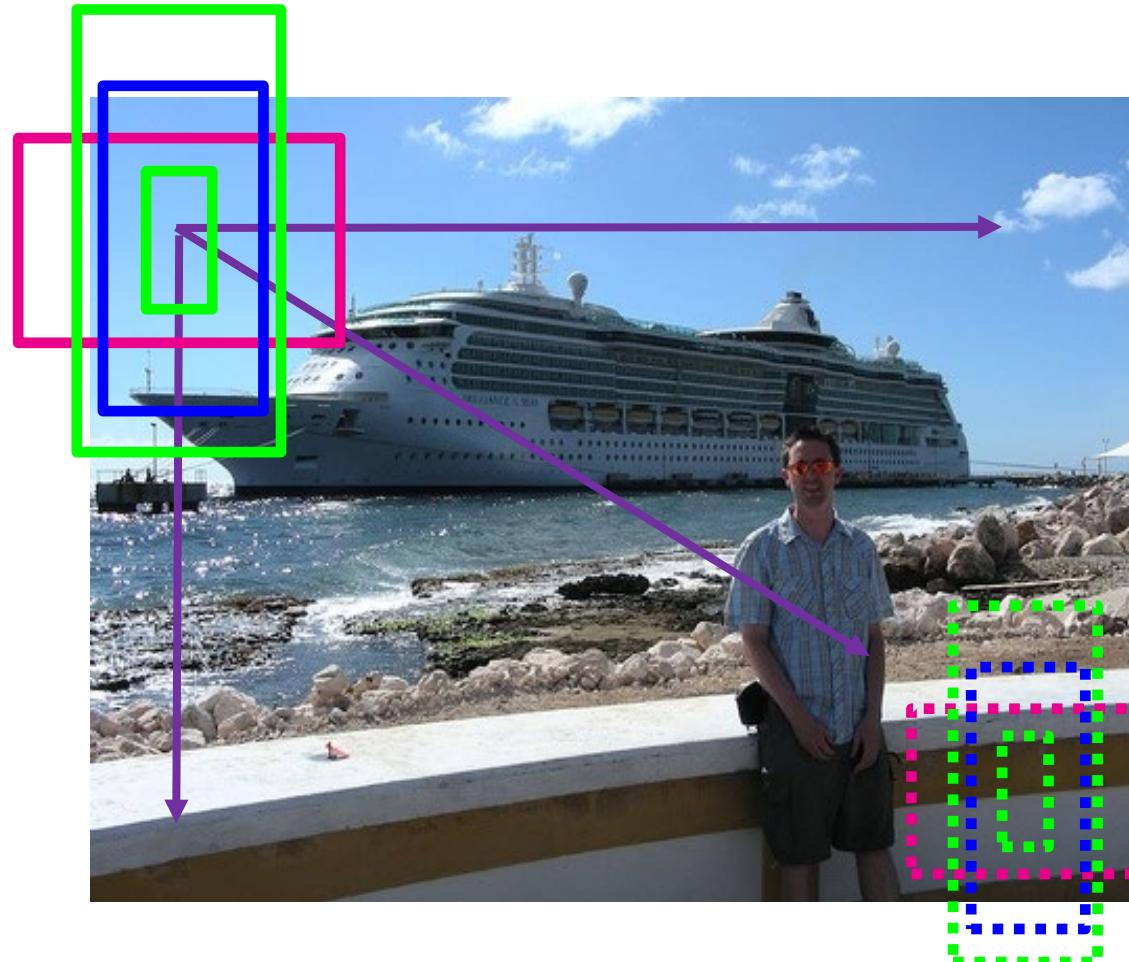
Faster RCNN 网络结构

- 特征提取网络：VGG、ResNet(去掉最后pooling层，下采样均为16)
- 候选区域**提取**网络（RPN），粗略获取物体潜在位置
- 候选区域**分类**网络：对RPN输出的候选区域进行多类分类以及位置精确调整
- 候选区域提取和分类网络**共享**特征提取部分



候选区域提取

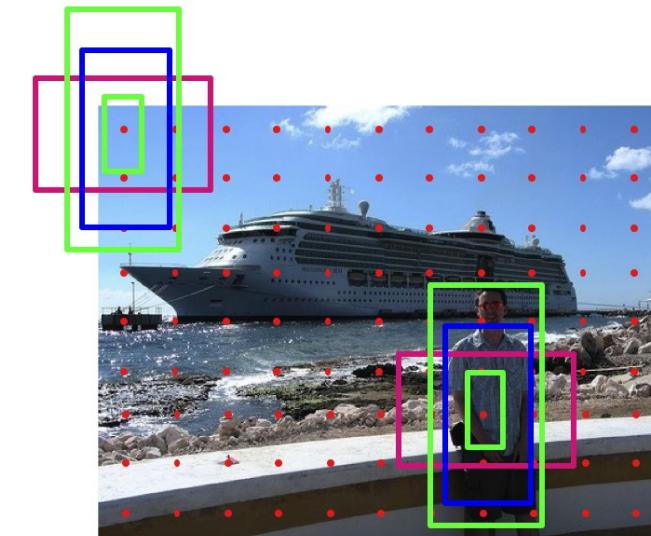
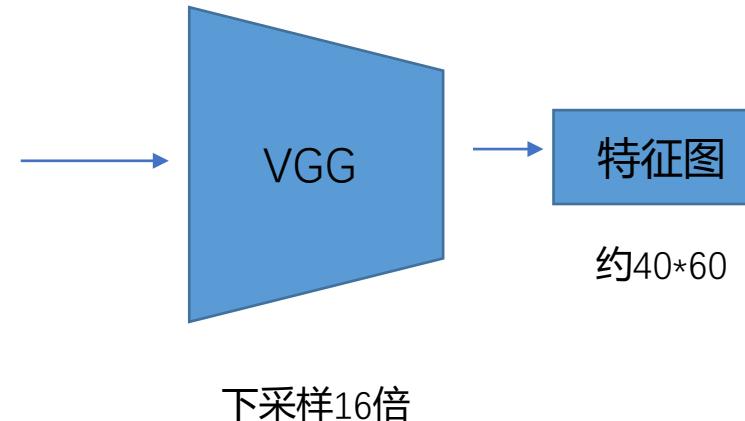
□ 滑动窗口检测



□ Region Proposal Network (RPN)

- Anchor: 9种尺度 (3种尺度, 3种长宽比)
- 锚点数量为最后feature map大小, 位置为原图中感受野的中心
- RPN的训练过程可以看做图像分割过程, 对feature map上每个点进行分类 (预测以当前点为中心, 哪些anchor覆盖物体, 哪些anchor属于背景)

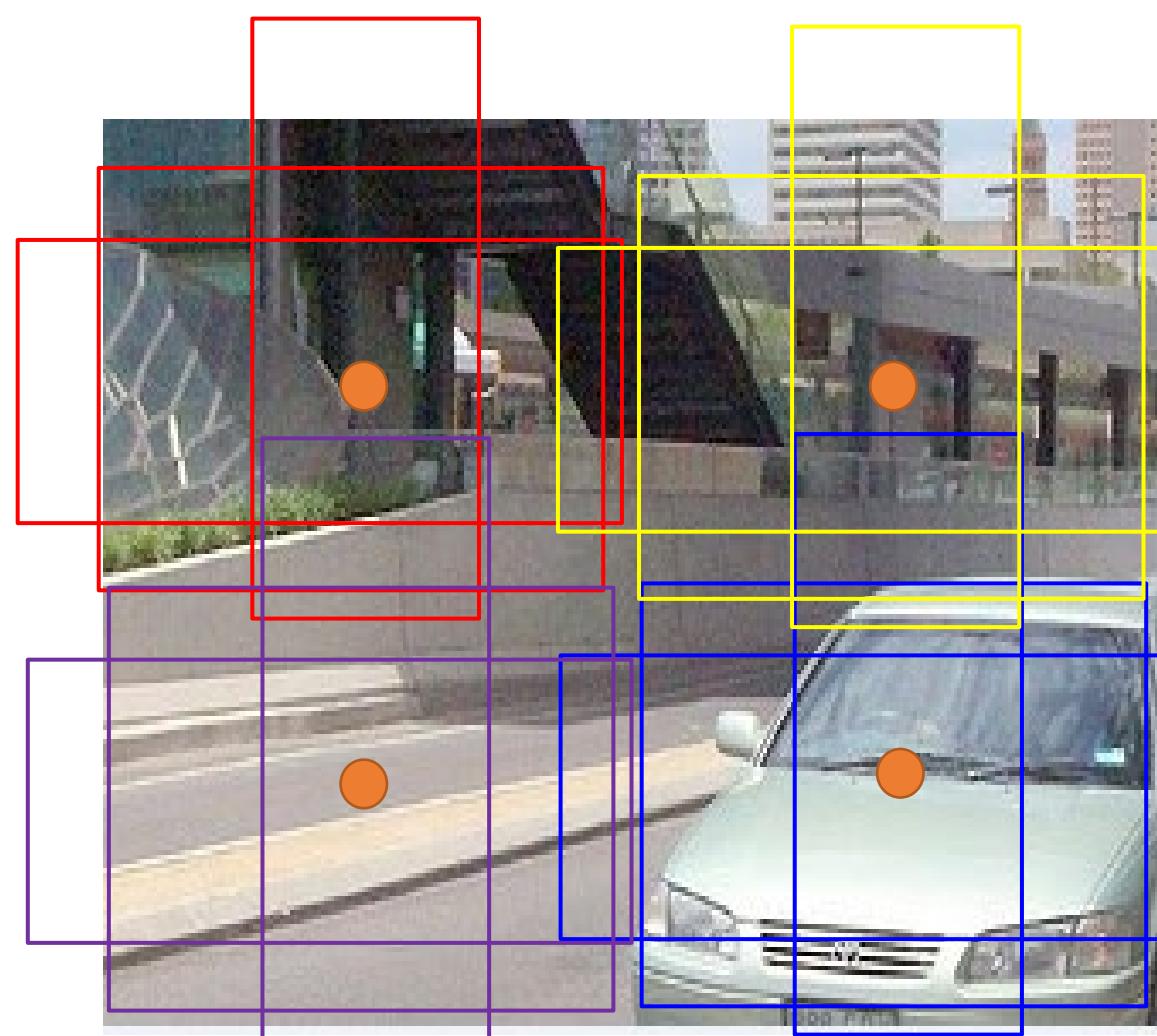
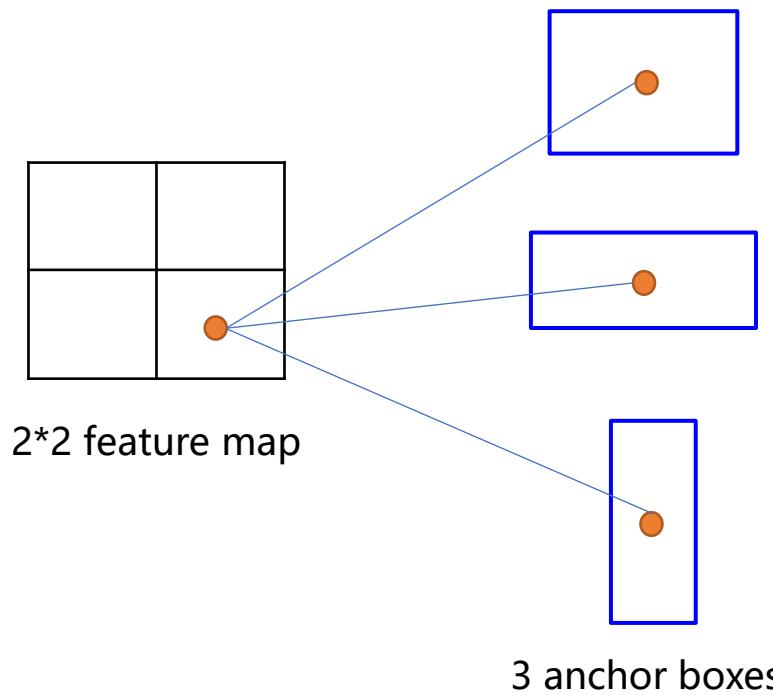
anchor	$128^2, 2:1$	$128^2, 1:1$	$128^2, 1:2$	$256^2, 2:1$	$256^2, 1:1$	$256^2, 1:2$	$512^2, 2:1$	$512^2, 1:1$	$512^2, 1:2$
proposal	188×111	113×114	70×92	416×229	261×284	174×332	768×437	499×501	355×715



候选区域提取RPN

举例：

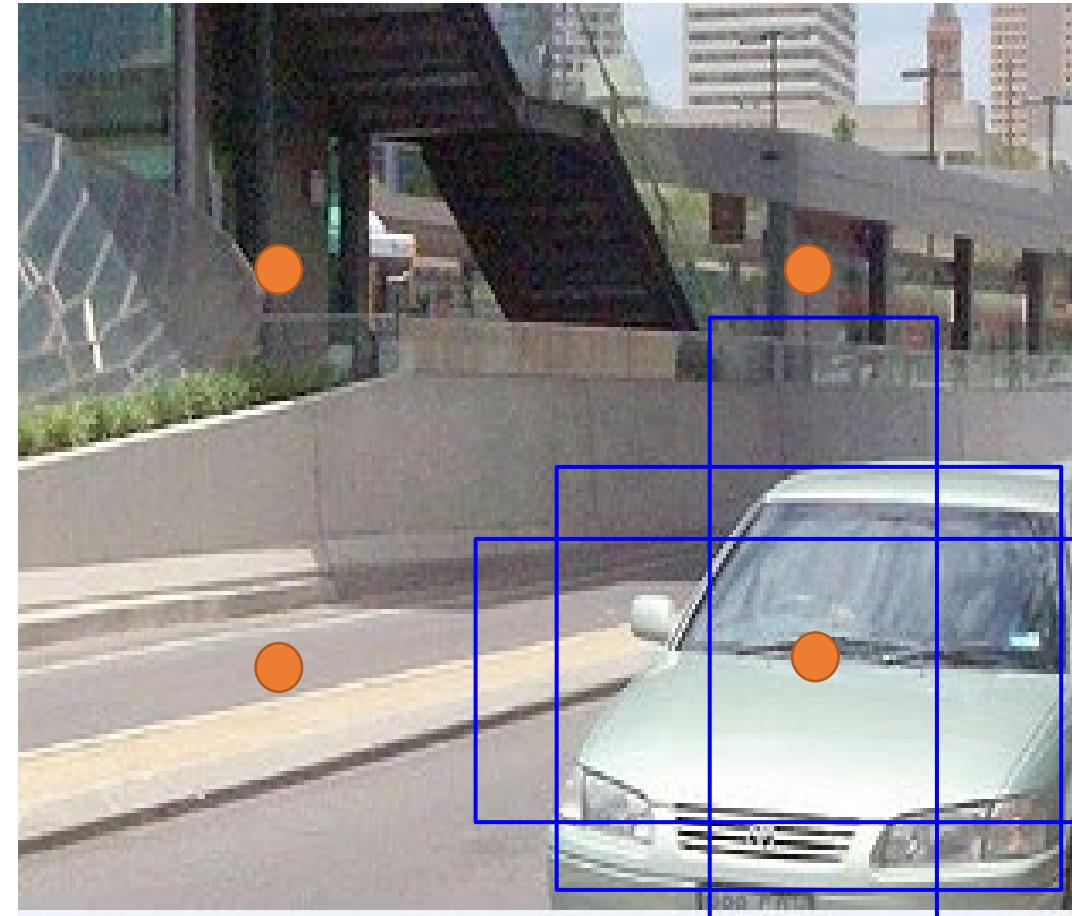
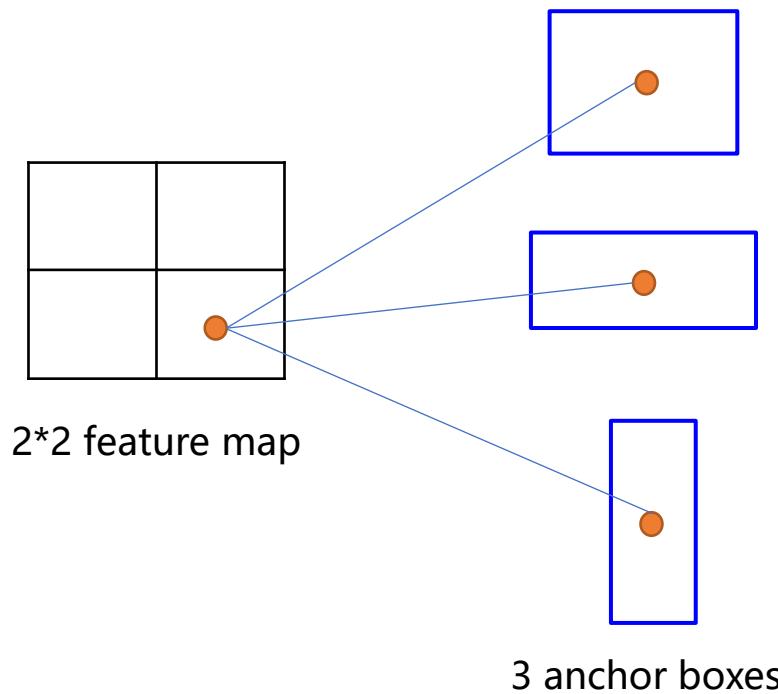
Feature map大小为 2×2 , 3种预设矩形框 (anchor box)



候选区域提取RPN

举例：

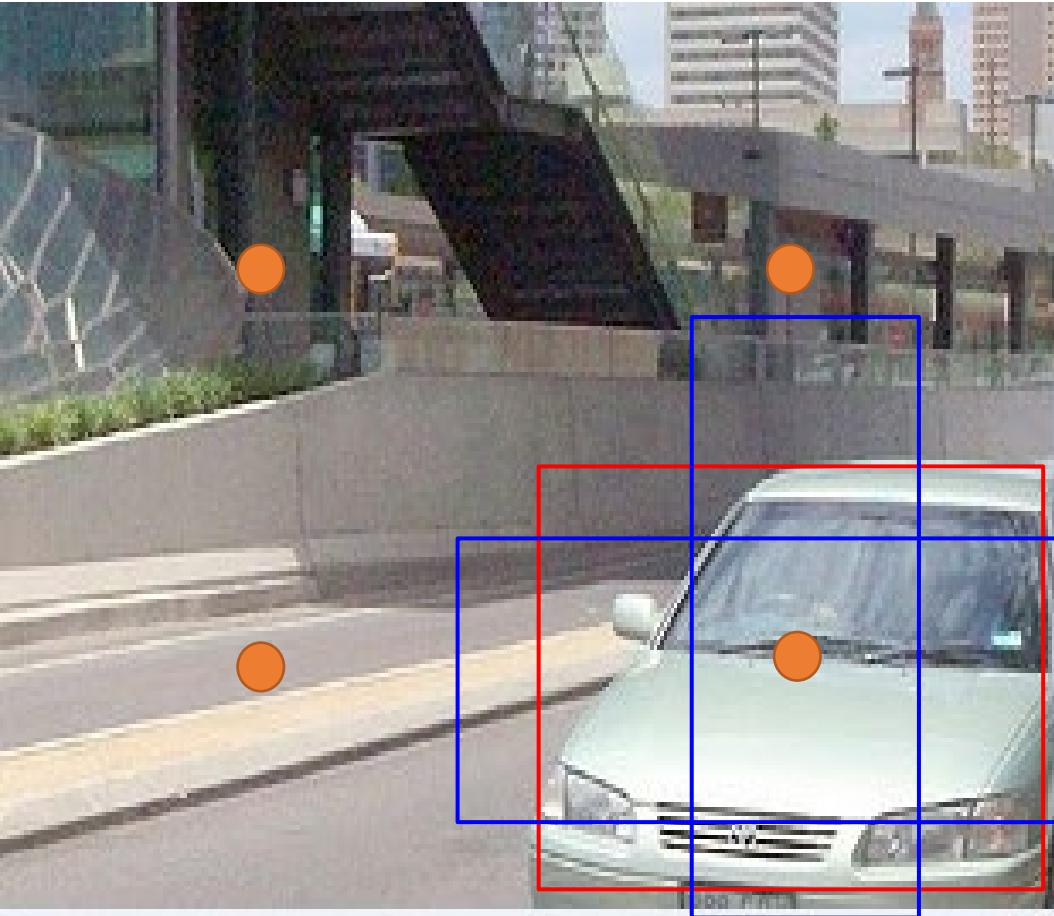
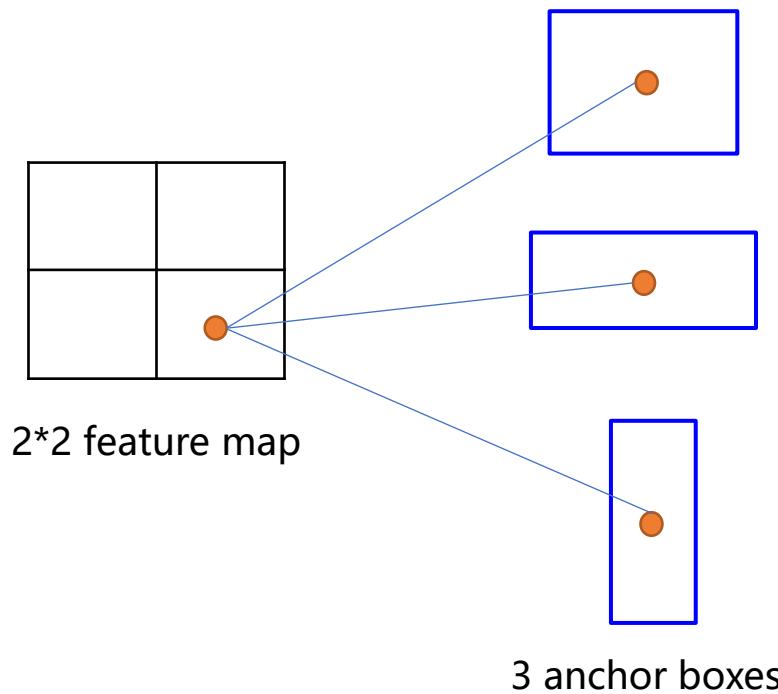
Feature map大小为 2×2 , 3种预设矩形框 (anchor box)



候选区域提取RPN

举例：

Feature map大小为 2×2 , 3种预设矩形框 (anchor box)

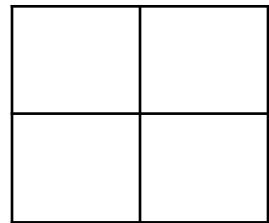


IOU > 0.7

候选区域提取RPN

举例：

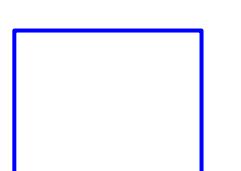
Feature map大小为 2×2 , 3种预设矩形框 (anchor box)



2×2 feature map

0	0
0	1

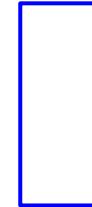
标签



0-背景

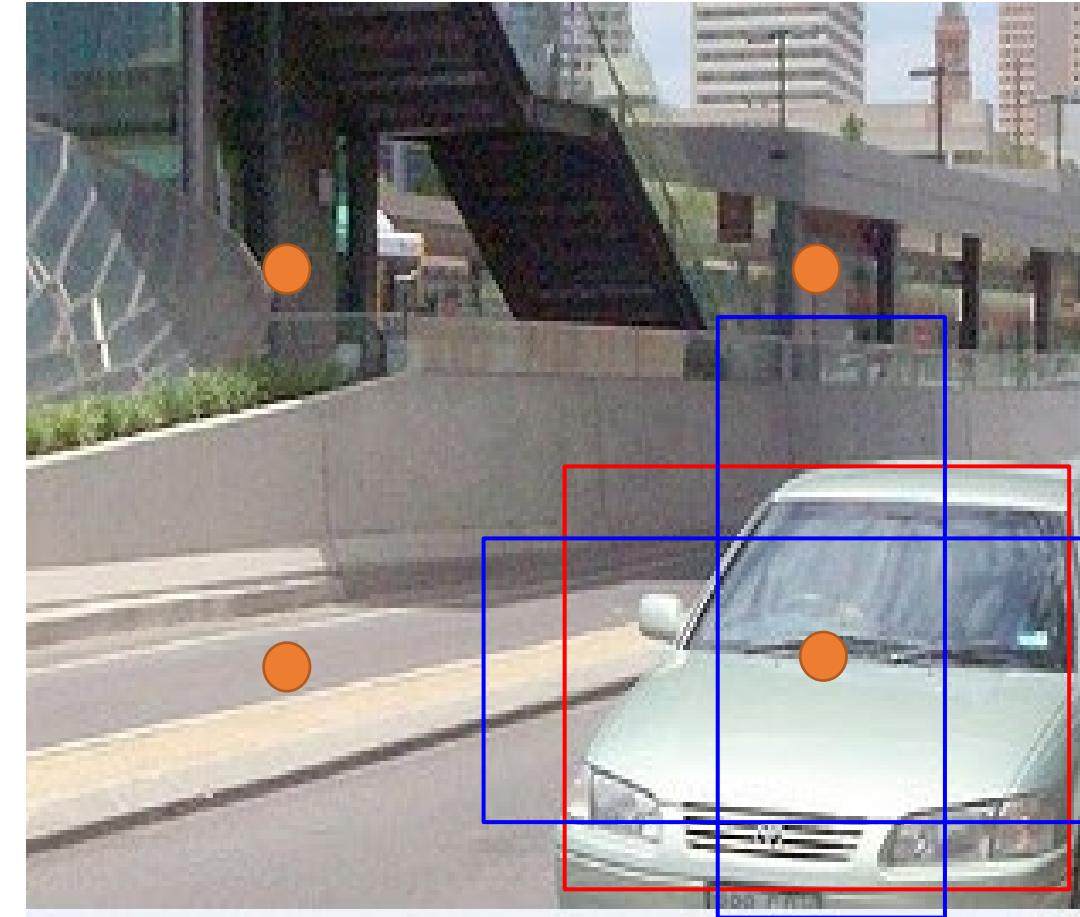


1



2

3



候选区域提取RPN

举例：

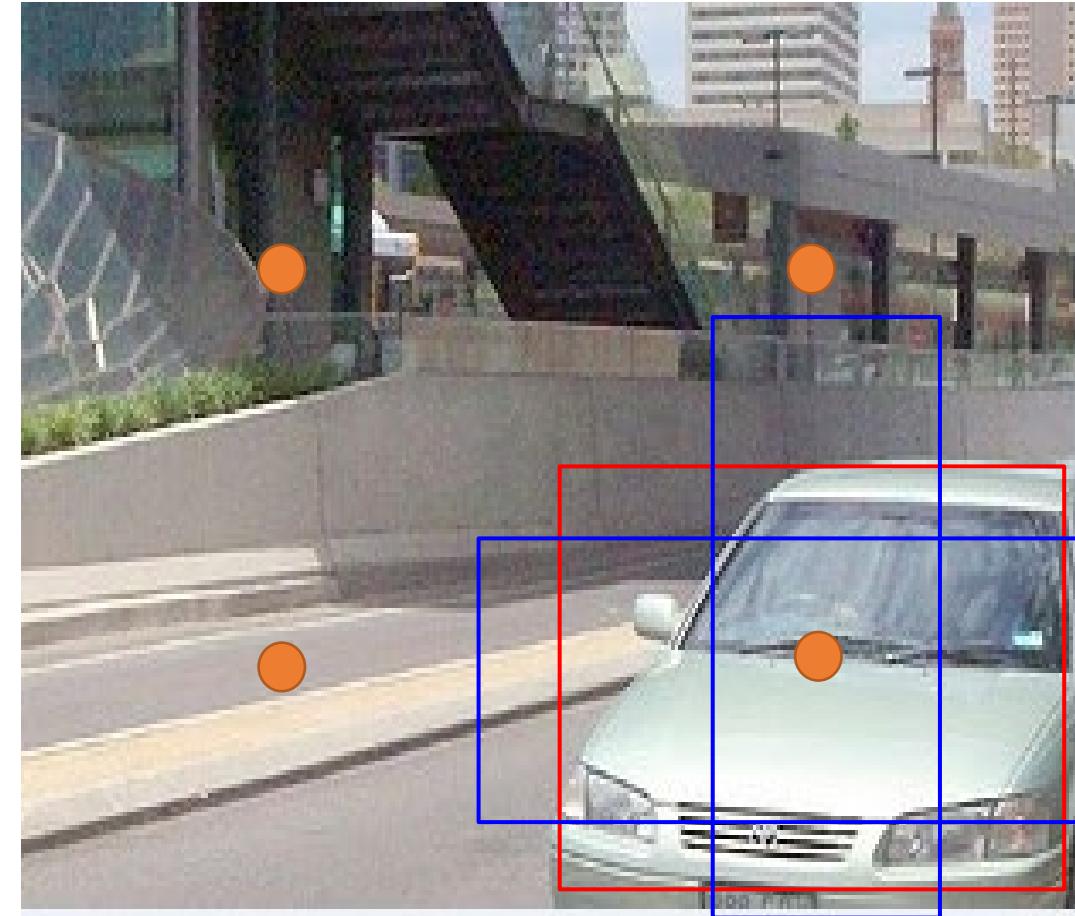
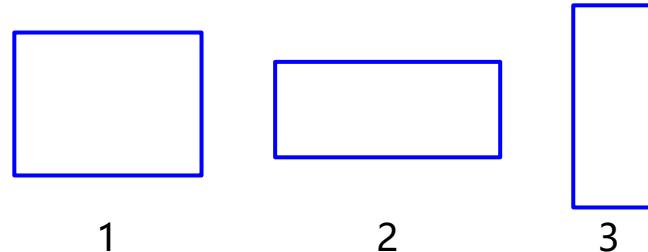
Feature map大小为 2×2 , 3种预设矩形框 (anchor box)



2×2 feature map

000	000
000	100

标签



为了降低学习难度，并产生更多的候选区域，采取二分类方式，并非one-hot的编码方式。

□ 前向传播

输入图像大小为 $H \times W$, 经过VGG得到 $\frac{H}{16} \times \frac{W}{16}$ 的特征, 输入到RPN网络得到:

分类的feature map: $N \times 2K \times \frac{H}{16} \times \frac{W}{16}$

坐标回归的feature map: $N \times 4K \times \frac{H}{16} \times \frac{W}{16}$

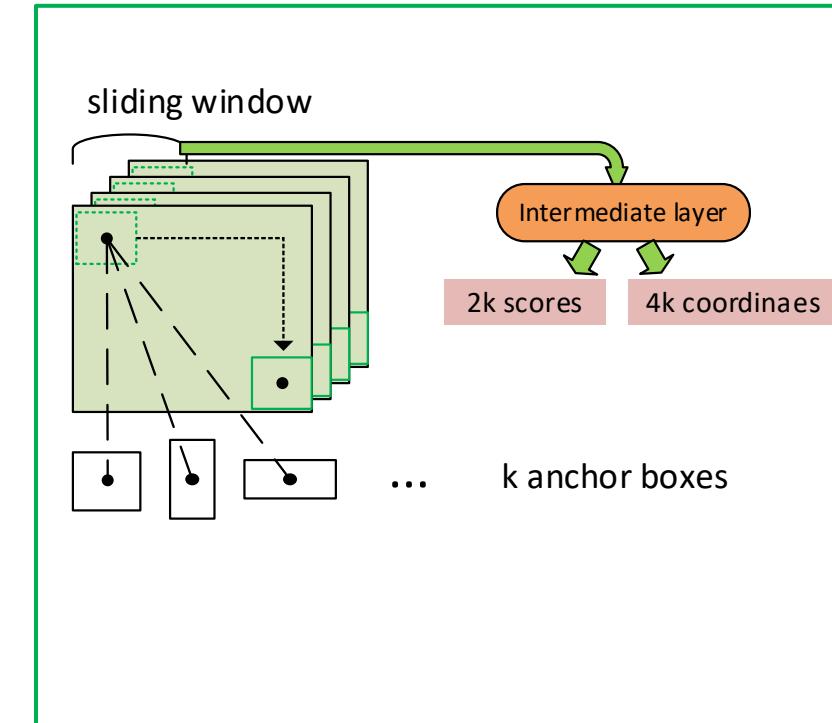
每个锚点预设 K 种 anchor box, faster RCNN 中 $K = 9$

□ Loss计算

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*).$$

分类损失

坐标回归损失



□ 分类损失计算：

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*).$$

□ Label生成：

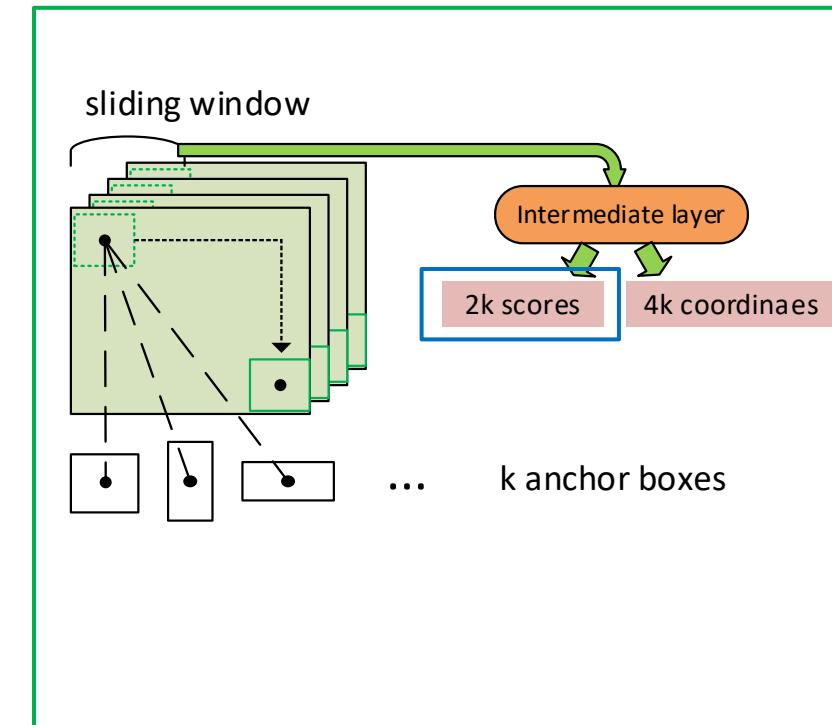
p_i, p_i^* : 预测的label和真实的label

L_{cls} : 交叉熵损失

- $p_i^* = 1$ if $\text{IoU} > 0.7$
- $p_i^* = 0$ if $\text{IoU} < 0.3$
- otherwise, do not contribute to loss

忽略IoU阈值在0.3-0.7之间的anchor box

(loss weight乘0即可实现)



RPN网络结构

□ 坐标回归损失计算:

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*).$$

$$L_{loc}(t, t^*) = \sum_{i \in \{x, y, w, h\}} smooth_{L_1}(t_i, t_i^*)$$

其中,

$$smooth_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases}$$

t_i, t_i^* : 预测位置偏差和真实的位置偏差

$t = \{x \ y \ w \ h\}$ (左上角坐标 xy , 宽高 wh)

□ Label生成

$$t_x^* = (x^* - x_a) / w_a$$

$$t_y^* = (y^* - y_a) / h_a$$

$$t_w^* = \log(w^* / w_a)$$

$$t_h^* = \log(h^* / h_a)$$



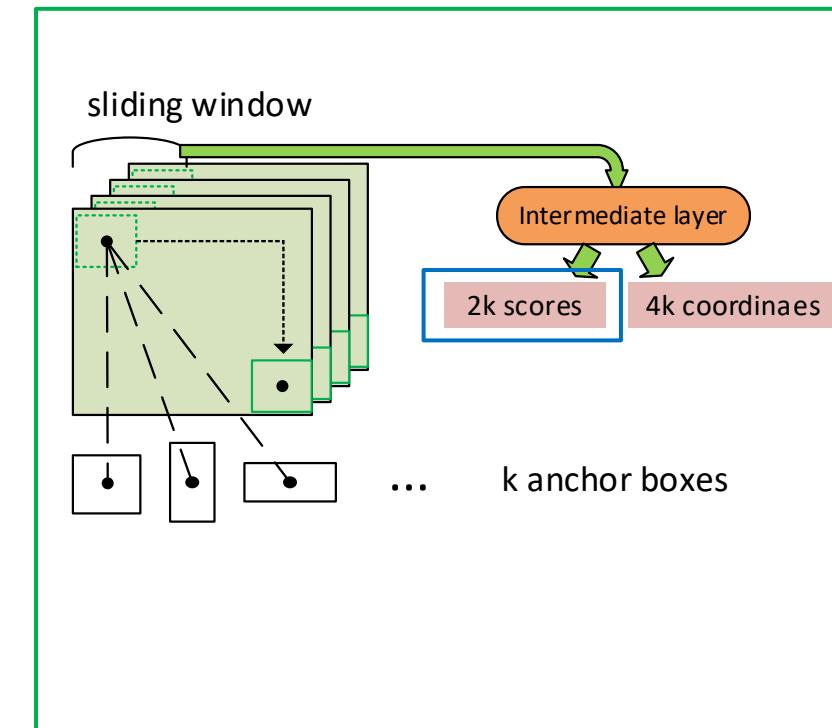
预测阶段:

$$x = t_x * w_a + x_a$$

$$y = t_y * h_a + h_a$$

$$w = \exp(t_w) * w_a$$

$$h = \exp(t_h) * h_a$$



□ 分类网络

作用：对RPN输出的候选区域进行分类（多类），并再次进行位置微调

Loss：与RPN阶段类似

$$L(p, u, t^u, v) = L_{\text{cls}}(p, u) + \lambda[u \geq 1]L_{\text{loc}}(t^u, v),$$

↑ 真实位置偏差 ↓ 预测位置偏差

↑ 真实label ↑ 多类交叉熵损失 ↑ Smooth L1 loss

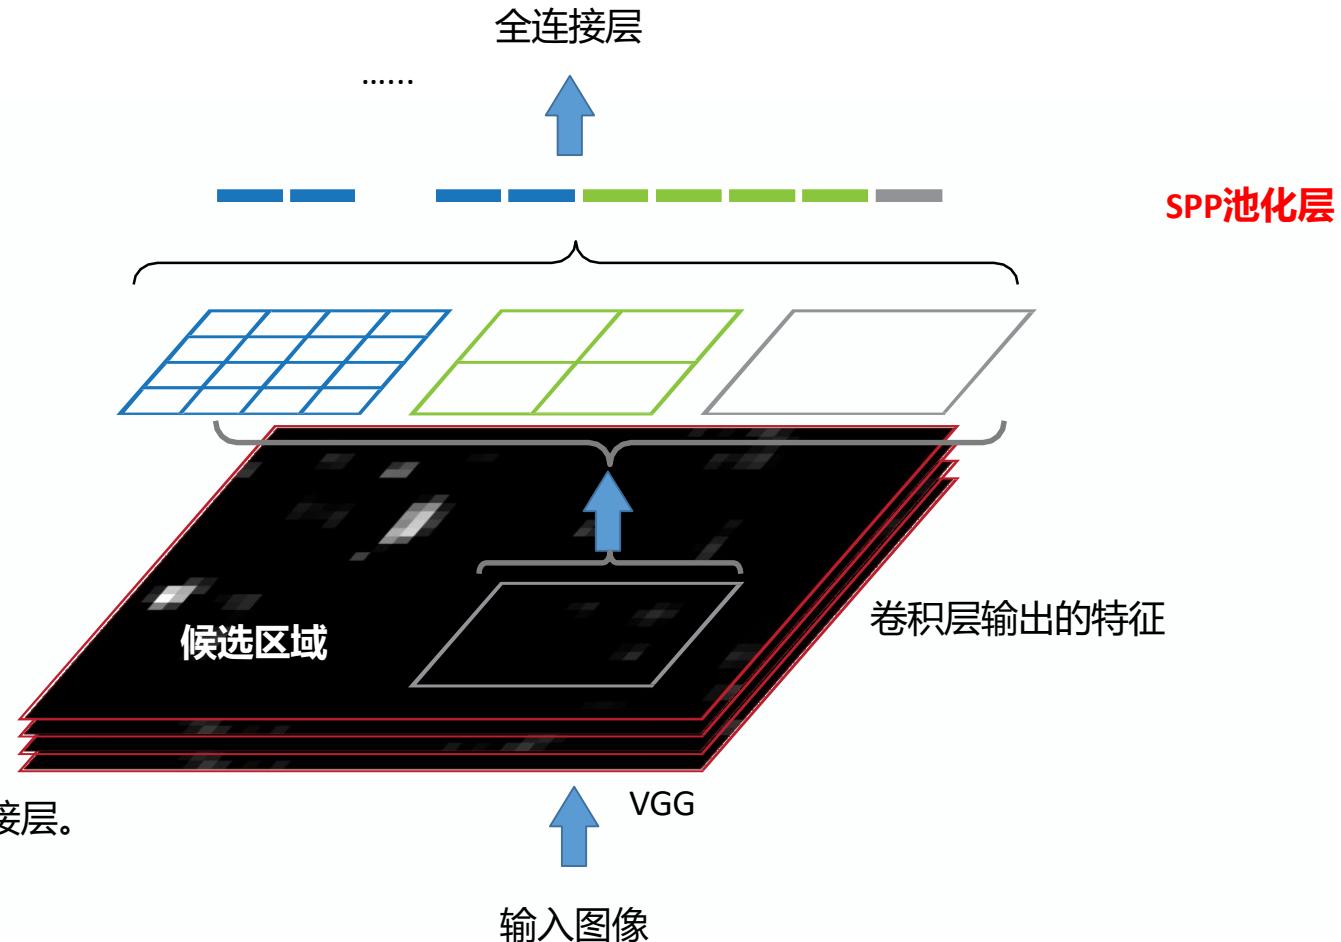
↑ 预测label

Faster RCNN—分类阶段

□ SPP池化层 (Spatial Pyramid Pooling)

输入特征大小: $w \times h \times c$

提取后特征尺寸: $4 \times 4 \times c + 2 \times 2 \times c + 1 \times 1 \times c$

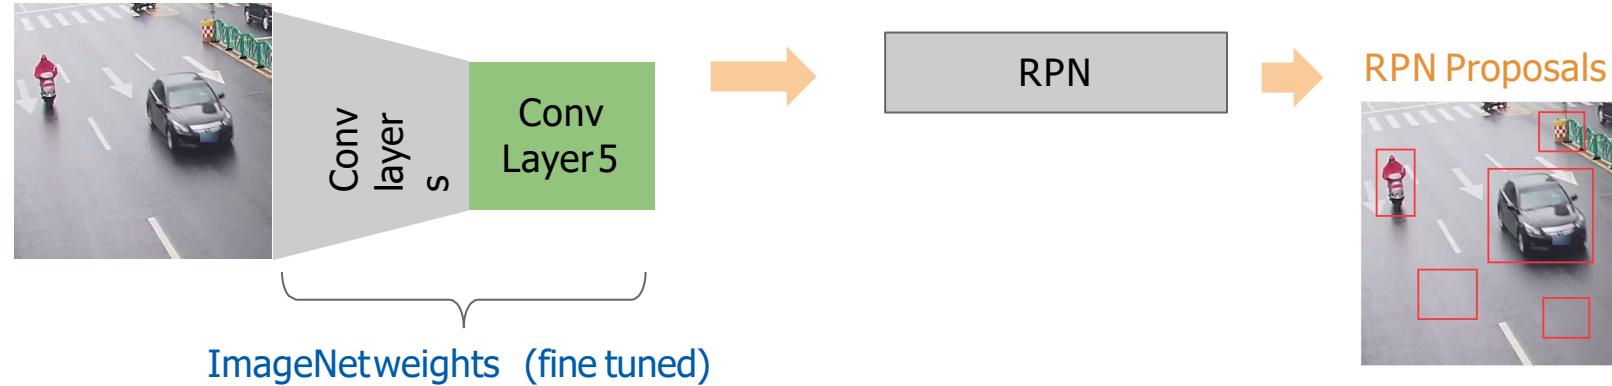


不同尺寸候选区域提取到同样维度的特征，便于输入全连接层。

Faster RCNN 训练细节

□ 四步骤训练

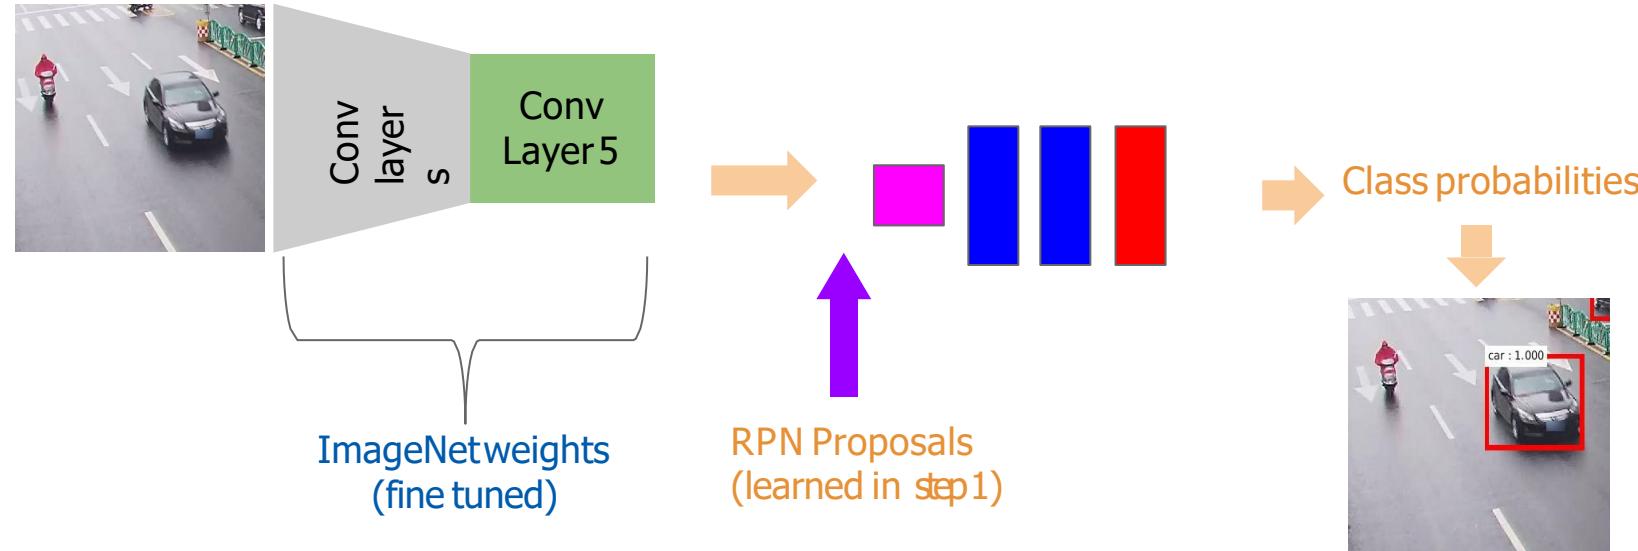
Step 1: 利用ImageNet模型初始化VGG，训练RPN网络。



Faster RCNN 训练细节

□ 四步骤训练

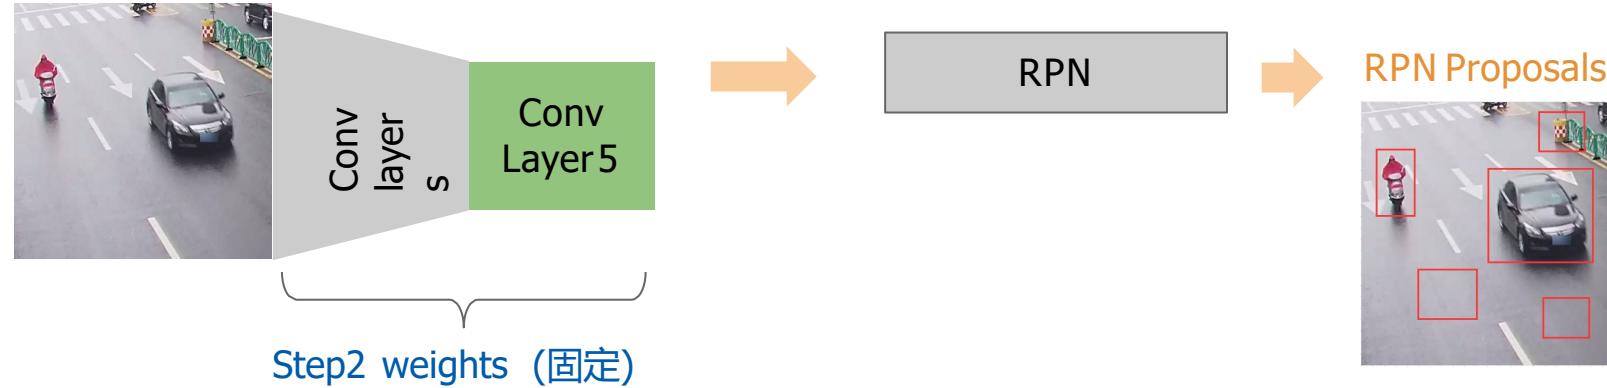
Step 2: 利用ImageNet模型初始化VGG，训练分类网络（在此过程中调用RPN的输出）



Faster RCNN 训练细节

□ 四步骤训练

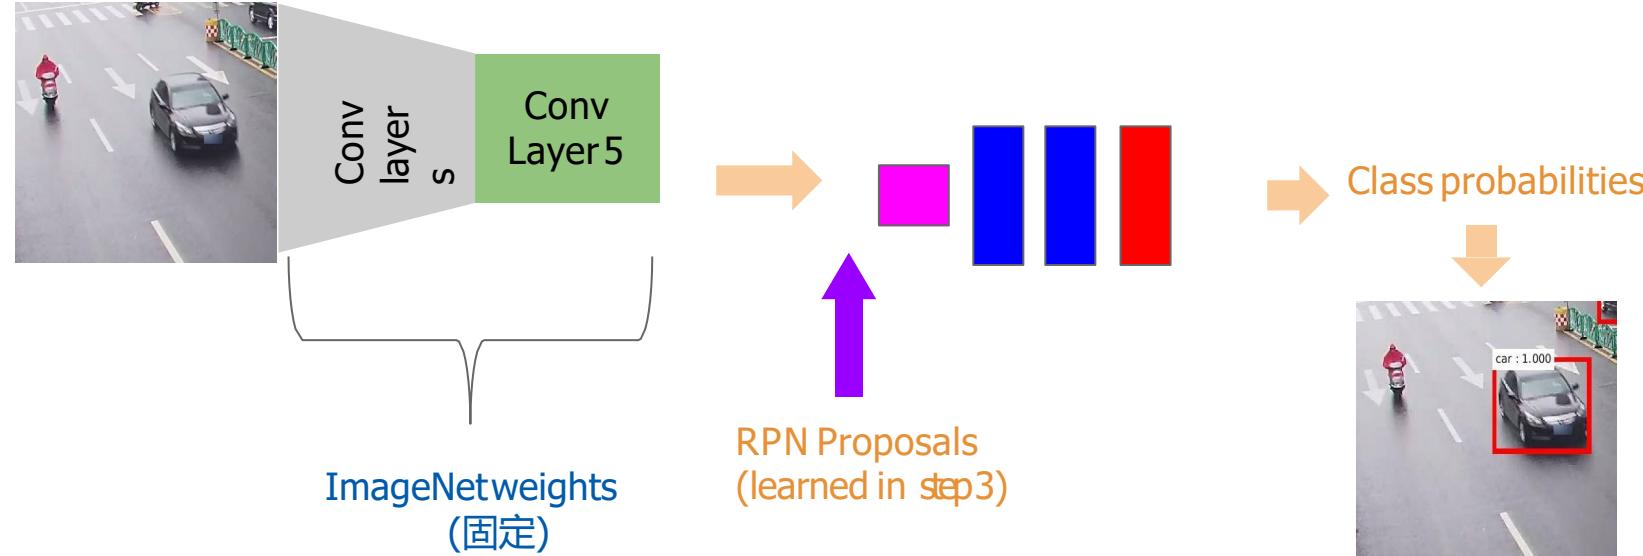
Step 3: 利用step 2模型初始化VGG，训练RPN网络.



Faster RCNN 训练细节

□ 四步骤训练

Step 4: 利用step 2&3模型初始化VGG, 训练分类网络 (在此过程中调用RPN的输出)



- ✓ 目标识别介绍
- ✓ 传统方法和深度学习对比
- ✓ Faster RCNN介绍
- ✓ Faster RCNN代码详解**

□ 运行环境: Linux, python 2.7/3.6, pytorch 0.4.0/0.4.1, CUDA 8.0+

□ 安装必要的python包: pip install -r requirements.txt

□ 下载并解压VOC数据集:

```
cd faster-rcnn.pytorch && mkdir data
```

```
ln -s /your/dataset VOCdevkit2007
```

□ 下载vgg16 pretrain model:

(https://www.dropbox.com/s/s3brpk0bdq60nyb/vgg16_caffe.pth?dl=0)

```
cd data && mkdir pretrained_model
```

```
ln -s /your/model vgg16_caffe.pth
```

1. Download the training, validation, test data and VOCdevkit

```
wget http://host.robots.ox.ac.uk/pascal/VOC/voc2007/VOCtrainval_06-Nov-2007.tar
wget http://host.robots.ox.ac.uk/pascal/VOC/voc2007/VOCtest_06-Nov-2007.tar
wget http://host.robots.ox.ac.uk/pascal/VOC/voc2007/VOCdevkit_08-Jun-2007.tar
```

2. Extract all of these tars into one directory named VOCdevkit

```
tar xvf VOCtrainval_06-Nov-2007.tar
tar xvf VOCtest_06-Nov-2007.tar
tar xvf VOCdevkit_08-Jun-2007.tar
```

3. It should have this basic structure

```
$VOCdevkit/                                # development kit
$VOCdevkit/VOCcode/                          # VOC utility code
$VOCdevkit/VOC2007                           # image sets, annotations, etc.
# ... and several other directories ...
```

4. Create symlinks for the PASCAL VOC dataset

```
cd $FRCN_ROOT/data
ln -s $VOCdevkit VOCdevkit2007
```

□ 编译一些辅助代码/层：

```
cd lib && sh make.sh
```

□ 目的：

```
python setup.py build_ext --inplace
```

- model/utils/bbox.pyx #计算box之间IoU
- pycocotools/maskApi.c #读取coco数据集中二值掩膜

```
model/nms/src/* #NMS gpu代码
```

```
model/roi_pooling/src #RoI pooling 层 (SPP空间金字塔池化的简化版)
```

```
model/roi_align/src # RoI align 层
```

```
model/roi_crop/src # RoI crop 层
```

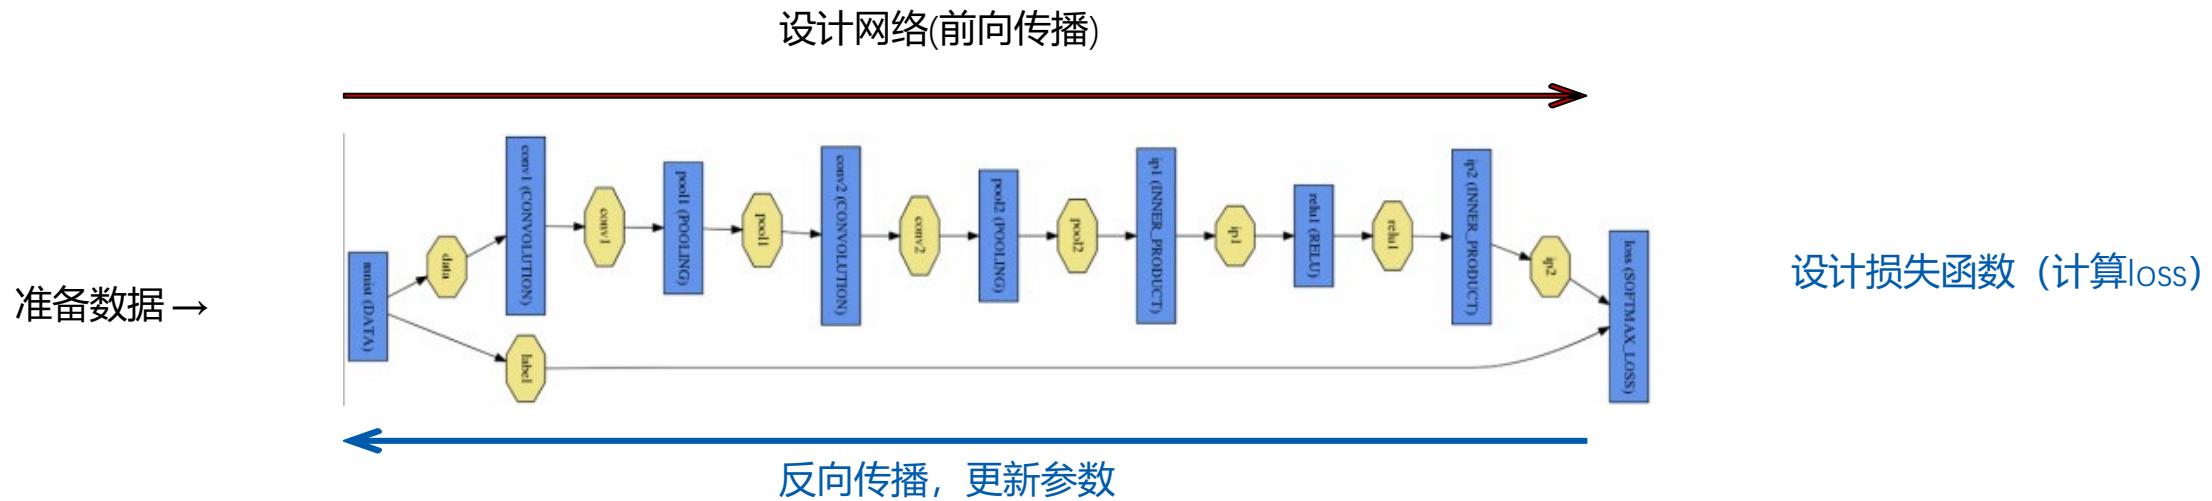
□ 用途：

- 实现新的功能，但是pytorch不支持
- 代码运行速度有要求

□ 途径—C拓展：

- 准备.c文件实现
- 利用工具编译为python可以调用的模块
- 嵌入到pytorch网络中

□ 实例展示



主函数: `trainval_net.py`

- 准备数据: Dataset+DataLoader
- 网络设计: vgg16+faster rcnn
- 损失计算: label准备, 调用loss计算
- 参数更新: for循环迭代

- 读取数据集中全部图像和gt boxes 信息到roidb, `lib/roi_data_layer/roidb.py::combined_roidb(args.imdb_name)`
- 利用roidb初始化dataset类, `lib/roi_data_layer/roidb.py:: class roibatchLoader(data.Dataset)`
- 用dataset初始化dataloader

dataset中getitem函数返回内容: `data, im_info, gt_boxes, num_boxes,`

其中利用`lib/roi_data_layer/minibatch.py:: get_minibatch`获取原始图像和gt boxes

注:

数据集图像的短边resize到600

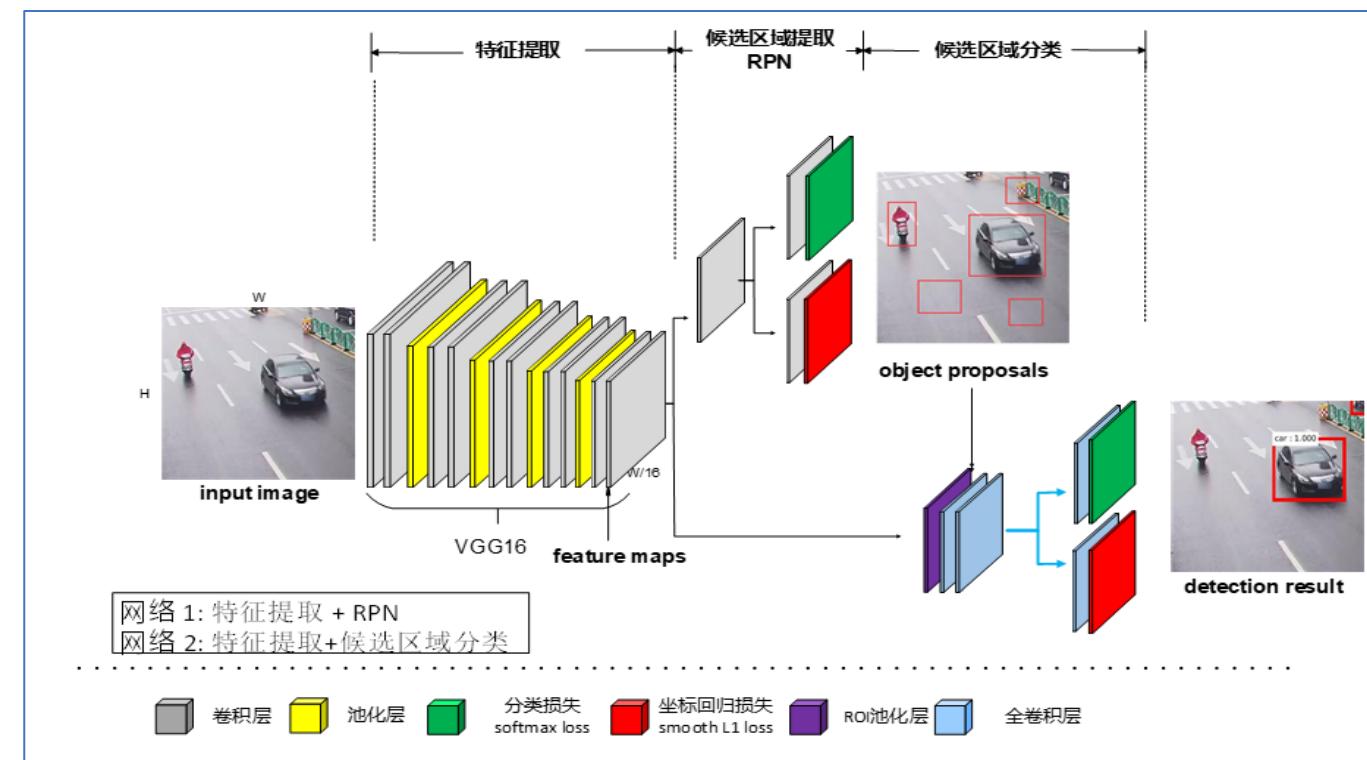
同一个batch中图像的长宽比保持一致

□ lib/model/faster_rcnn

- vgg16.py
- resnet.py
- 全部继承_fasterRCNN(lib/model/faster_rcnn/faster_rcnn.py)

□ 主要的类成员:

```
self.RCNN_base #vgg网络部分  
self.RCNN_rpn    #RPN部分  
self.RCNN_cls_score # fast rcnn 分类  
self.RCNN_bbox_pred #fast rcnn 坐标回归
```

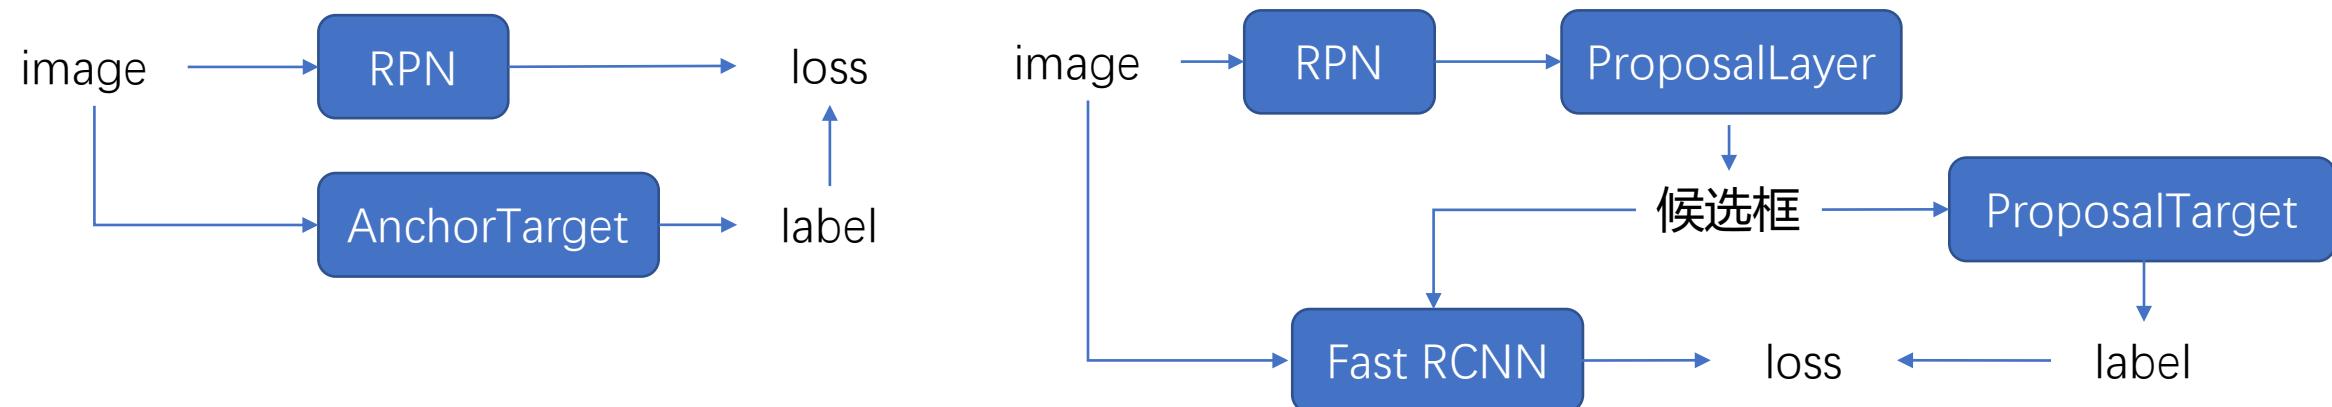


损失计算—生成各种label

□ 三个layer

- AnchorTargetLayer：负责在训练RPN的时候，从上万个anchor中选择一些(比如256)进行训练，以使得正负样本比例大概是1:1. 同时给出训练的位置参数目标。即返回`gt_rpn_loc`和`gt_rpn_label`。
- ProposalLayer：在RPN输出的候选区域，选取得分较高的N个候选框，然后进行NMS，然后选择一定数目 (2000或者300)，用以候选区域分类训练或者测试。
- ProposalTargetLayer：负责在训练候选区域分类的时候，从RoIs选择一部分(比如128个)用以训练。同时给定训练目标，返回`(sample_RoI, gt_RoI_loc, gt_RoI_label)`

AnchorTargetCreator和ProposalTargetCreator是为了生成训练的目标，只在训练阶段用到，ProposalLayer是RPN为第二个分类网络生成RoIs，在训练和测试阶段都会用到。三个共同点在于他们都不需要考虑反向传播。

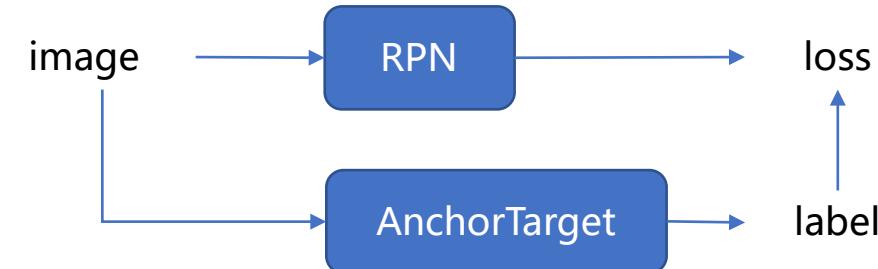
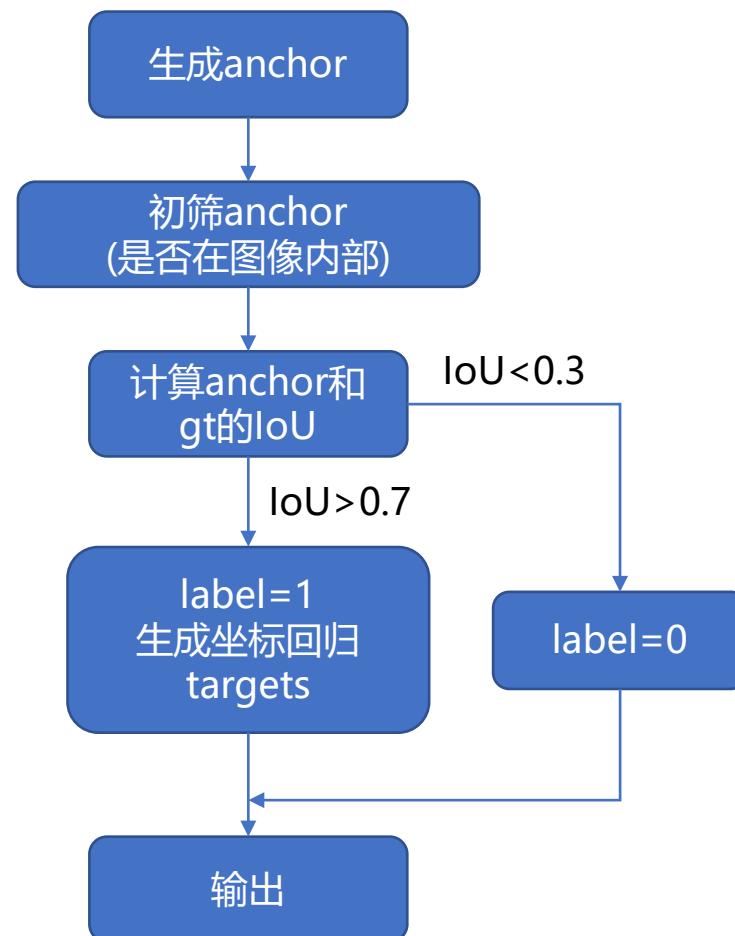


□ 关于矩形框的描述：

- Bbox: bounding box, 边界框。其中Ground Truth Bounding Box是每一张图中人工标注的框的位置。一张图中有几个目标，就有几个框(一般小于10个框)。Faster R-CNN的预测结果也可以叫bounding box，不过一般叫 Predict Bounding Box.
- Anchor: 人在图像中假想的具有一定尺度、比例的框。一个feature map的锚的数目有上万个 (比如 20000) 。
- RoI: region of interest, 候选矩形框。Faster R-CNN之前传统的做法是利用selective search从一张图上大概2000个候选框框。现在利用RPN进行候选框提取。
- loc: bbox, anchor和RoI, 本质上都是一个框，可以用四个数 ($y_{min}, x_{min}, y_{max}, x_{max}$) 表示框的位置，还可以用 (y, x, h, w) 表示，即框的中心座标和长宽。Ground truth中记录的是前一种方式，在训练中进行位置回归的时候，用的是后一种的表示。

AnchorTargetLayer

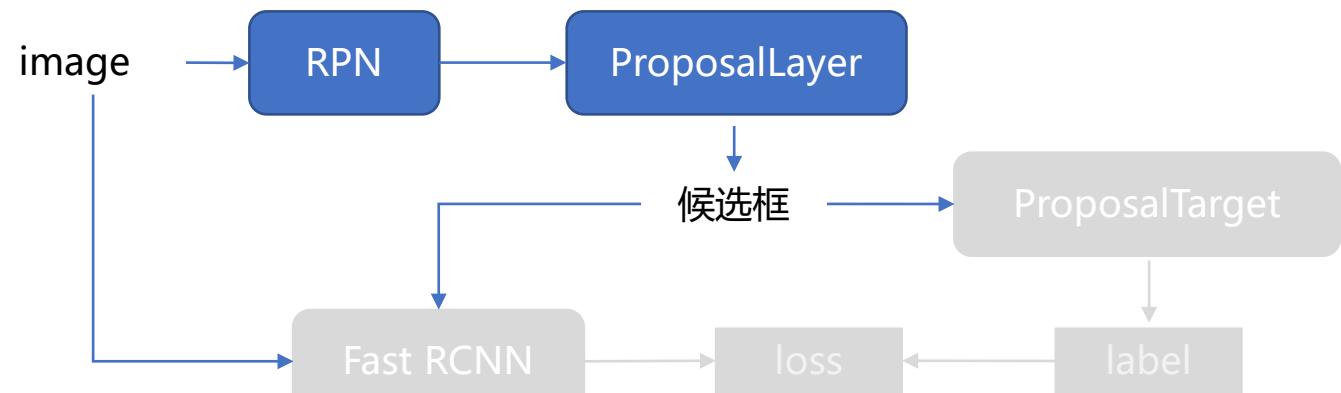
负责在训练RPN的时候，从上万个anchor中选择一些(比如256)进行训练，以使得正负样本比例大概是1:1. 同时给出训练的位置参数目标。即返回`gt_rpn_loc`和`gt_rpn_label`。



并非所有符合条件的anchor都参与计算，每张图像选取随机选取256个anchor参与计算，其中正负样本比例为1:1。

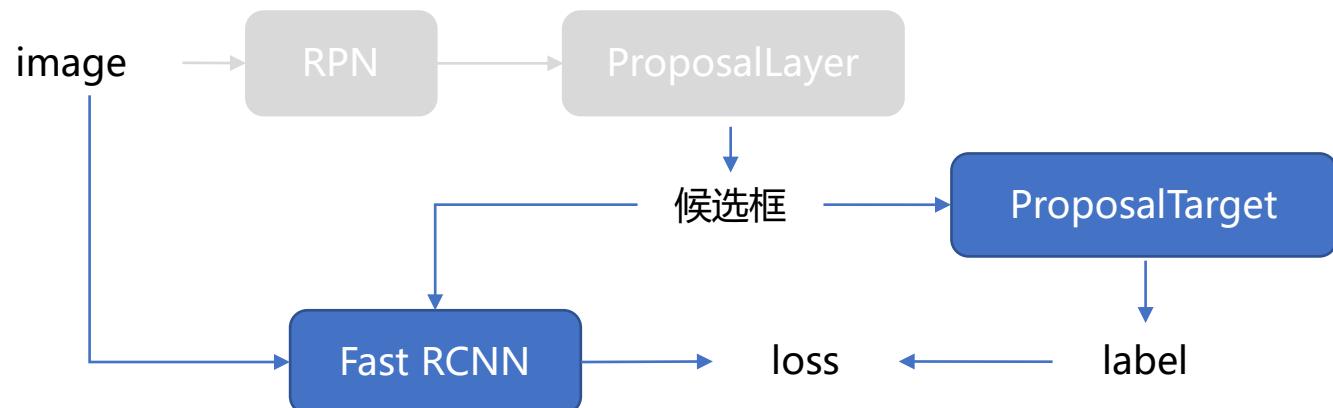
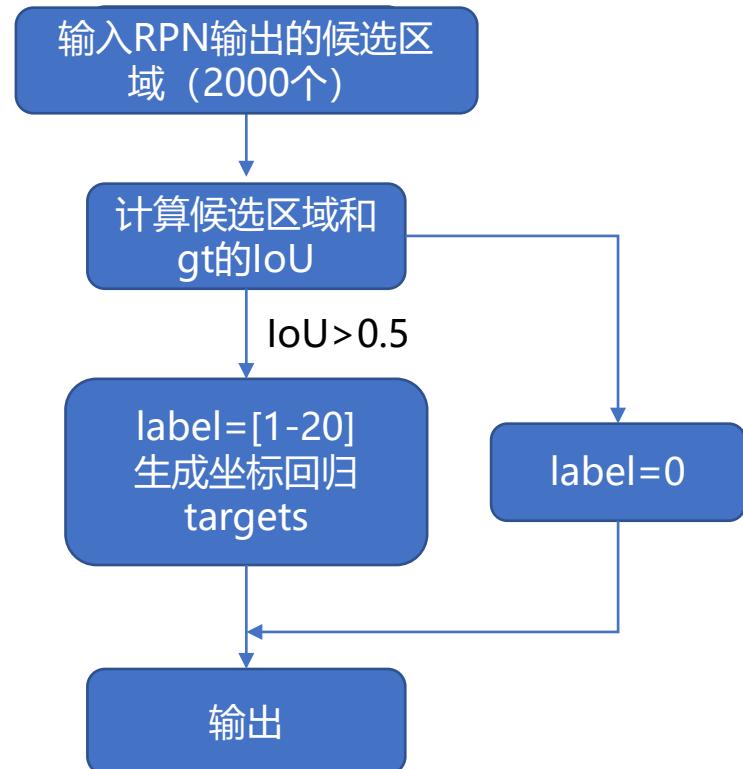
ProposalLayer

在RPN输出的候选区域，选取得分较高的N个候选框，然后进行NMS，然后选择一定数目（2000或者300），用以候选区域分类训练或者测试



ProposalTargetLayer

负责在训练候选区域分类的时候，从Rois选择一部分(比如128个)用以训练。同时给定训练目标，返回 (sample_Roi, gt_Roi_loc, gt_Roi_label)



并非所有符合条件的候选区域都参与计算。每张图像，选取随机选取128个参与计算，其中正负样本比例为1:3。

□ 四个损失

- RPN 分类损失: anchor是否为前景 (二分类)
- RPN位置回归损失: anchor位置微调
- RoI 分类损失: RoI所属类别 (21分类, 多了一个类作为背景)
- RoI位置回归损失: 继续对RoI位置微调

四个损失相加作为最后的损失, 反向传播, 更新参数。

□ 对比可视化FasterRCNN两个阶段

- RPN阶段得分最高的20个框（即proposal layer的输出top-20）
- 该top-20精细化分类后的结果

感谢各位聆听
Thanks for Listening